Sistema Embarcado e Distribuído para Detecção de Sonolência ao Volante Baseado em Fusão Multimodal de Sensores

Felipe Gabriel de Carvalho [1], Gabriel Henrique de Morais [1], Thiago Henrique Gomes Feliciano [1], Gustavo Henrique dos Santos Dias [1]

[1]Curso de Ciência da Computação – PUC-Minas
Belo Horizonte – MG – Brasil

{1543790, 1516239, 1543536, 1543570}@pucminas.edu.br

Abstract. *Drowsy driving is one of the leading causes of traffic accidents, accounting for a significant share of the fatal crashes recorded every year. This work proposes an embedded and distributed system for drowsiness detection, integrating three complementary sensing modalities – visual (camera), physiological (smartwatch via PPG/HRV) and mechanical (steering wheel grip force) – processed by a Raspberry Pi acting as the fusion and decision node. The proposal covers Computer Architecture and Computer Networks, encompassing the development of a signal acquisition and fusion pipeline and a distributed communication protocol for alert transmission. Validation follows an experimental measurement model, with a priori data collection, per-driver calibration, and metrics of accuracy, computational performance, energy consumption and network behavior.*

Resumo. *A sonolência ao volante é uma das principais causas de acidentes de trânsito, respondendo por parcela significativa dos acidentes fatais registrados anualmente. Este trabalho propõe um sistema embarcado e distribuído para detecção de sonolência, integrando três modalidades de sensoriamento complementares, sendo eles visual (câmera), fisiológica (smartwatch via PPG/HRV) e mecânica (força de aperto no volante), processadas por um Raspberry Pi que atua como nó de união em uma árvore de decisão. A proposta abrange as áreas de Arquitetura de Computadores e Redes de Computadores, contemplando o desenvolvimento de um pipeline de aquisição e junção de sinais e um protocolo de comunicação distribuída para transmissão de alertas. A validação seguirá um modelo de medição experimental, com coleta de dados a priori, calibração individual por motorista e métricas de precisão, desempenho computacional, consumo energético e comportamento de rede.*

1. Introdução

A fadiga e a sonolência ao volante constituem um dos fatores humanos mais relevantes na causalidade de acidentes de trânsito em todo o mundo. Segundo dados da National Highway Traffic Safety Administration (NHTSA), motoristas sonolentos estiveram envolvidos em aproximadamente 91.000 acidentes registrados pela polícia em 2017, resultando em cerca de 50.000 feridos e quase 800 mortes somente nos Estados Unidos [Peker et al. 2026]. Estudos apontam que entre 20% e 30% dos acidentes de trânsito no mundo estão relacionados à sonolência do condutor, chegando a 35%–45% em condições

de direção monótona [Peker et al. 2026]. No Brasil, dados de órgãos de trânsito também apontam a fadiga como fator determinante em parcela expressiva dos acidentes rodoviários [Ma'ajid and Al-Khowarizmi 2025].

Diante desse cenário, diversas tecnologias vêm sendo propostas para a detecção antecipada da sonolência, podendo ser classificadas em quatro grandes famílias: (i) sistemas baseados em veículo, que analisam o comportamento de condução (ângulo do volante, desvio de faixa); (ii) sistemas baseados em visão computacional, que extraem indicadores faciais como o Eye Aspect Ratio (EAR) e o PERCLOS (Percentage of Eyelid Closure); (iii) sistemas fisiológicos, que utilizam sinais biológicos como EEG, ECG, HRV (Heart Rate Variability) e PPG (Fotopletismografia); e (iv) sistemas mecânicos, como sensores de força de preensão no volante [Sahmarany et al. 2026, Peker et al. 2026]. Cada uma dessas modalidades, isoladamente, apresenta limitações conhecidas: sistemas de visão são sensíveis a condições de iluminação e oclusões (óculos, ângulo de câmera); sistemas fisiológicos costumam exigir contato direto e apresentam maior intrusividade e custo; e sistemas mecânicos falham quando o motorista retira as mãos do volante por qualquer motivo [Peker et al. 2026, Sahmarany et al. 2026].

1.1. Problema e Hipótese

O problema central deste trabalho é: como detectar precocemente estados de sonolência do motorista de forma não invasiva, de baixo custo e tecnicamente escalável, minimizando as limitações individuais de cada modalidade de sensoriamento isolada? A hipótese adotada é que a junção de sinais provenientes de diferentes fontes (visual, fisiológica e mecânica) processada em uma árvore de decisão local, combinada com uma etapa de calibração individual por motorista, permite maior segurança de detecção do que qualquer sensor isolado, sem exigir hardware de laboratório (EEG, por exemplo) e aproveitando dispositivos já amplamente difundidos, como *smartwatches* comerciais equipados com sensores PPG.

1.2. Objetivos

Objetivo geral: projetar, implementar e avaliar um sistema embarcado e distribuído de detecção de sonolência ao volante, baseado na fusão de sinais visuais, fisiológicos e mecânicos, processados em um Raspberry Pi.

Objetivos específicos:

- Implementar a aquisição de sinais visuais (EAR/PERCLOS) via câmera conectada ao Raspberry Pi;
- Implementar a aquisição de frequência cardíaca (PPG/HRV) via comunicação Bluetooth Low Energy (BLE) com um *smartwatch* comercial;
- Projetar e calibrar um circuito de leitura de força de aperto no volante baseado em sensor FSR (Force Sensitive Resistor);
- Definir um algoritmo de fusão ponderada das três modalidades, calibrado por meio de uma etapa de coleta de dados de referência (*baseline*) individual por motorista;
- Implementar a transmissão distribuída dos dados e dos alertas via protocolo de rede leve (MQTT);
- Avaliar o sistema quanto à acurácia de detecção, ao desempenho computacional (tempo de resposta, uso de recursos, consumo energético) e ao comportamento de rede (latência, taxa de transmissão, escalabilidade).

1.3. Estrutura do Artigo

Este artigo está organizado da seguinte forma: a Seção 2 apresenta a revisão bibliográfica e os trabalhos correlatos que fundamentam a proposta; a Seção 3 descreve a metodologia de desenvolvimento e avaliação, o estado atual da implementação e os ajustes realizados em relação à proposta original, incluindo o cronograma de atividades; a Seção 4 delimita o tema, o escopo e as limitações do trabalho; e a Seção 5 apresenta as considerações finais desta proposta.

2. Revisão Bibliográfica

A literatura sobre detecção de sonolência veicular é extensa e pode ser organizada, de forma consolidada, segundo uma taxonomia orientada ao grau de intrusividade do sensoriamento, conforme proposto por Peker et al. [Peker et al. 2026]. Os autores realizam uma revisão comparativa abrangente cobrindo sistemas veiculares, visuais, fisiológicos e híbridos, destacando que a comparabilidade entre estudos é frequentemente prejudicada por diferenças na definição do *ground truth* (rótulos subjetivos como a escala KSS, Karolinska Sleepiness Scale, *versus* rótulos comportamentais como PERCLOS ou avaliação de observadores), no protocolo de aquisição (ambiente simulado *versus* condução real) e na unidade temporal de decisão (janelas de segundos, minutos ou eventos). Esse trabalho fundamenta diretamente a arquitetura híbrida que propomos, uma vez que evidencia, a partir da síntese de dezenas de estudos, que sistemas multimodais tendem a reduzir a dependência de uma única fonte de sinal e a compensar falhas específicas de cada modalidade isolada.

Complementarmente, El Sahmarany et al. [Sahmarany et al. 2026] apresentam uma revisão focada em tecnologias de sensoriamento e parâmetros fisiológicos para detecção em tempo real, comparando sistematicamente métodos mecânicos (respiração, força de aperto, piscar de olhos, câmera) e fisiológicos (EEG, ECG, GSR, PPG) quanto a critérios de capacidade de operação em tempo real, nível de fixação ao corpo, custo, restrição de movimento do motorista e possibilidade de operação autônoma. Esse referencial é relevante para a presente proposta, pois fornece diretamente os parâmetros de referência de custo e intrusividade utilizados na justificativa da escolha do sensor FSR de força de aperto e do sensor PPG embarcado em *smartwatch* comercial, em vez de alternativas mais caras e intrusivas, como EEG.

No que se refere especificamente à modalidade visual, Ma'ajid e Al-Khowarizmi [Ma'ajid and Al-Khowarizmi 2025] implementam um sistema de detecção baseado em visão computacional que combina o cálculo do Eye Aspect Ratio (EAR) com um classificador CNN (Convolutional Neural Network) e a extração de pontos faciais via MediaPipe FaceMesh, reportando acurácia de aproximadamente 99,5% em conjunto de teste. Esse trabalho fundamenta tecnicamente o módulo de visão do sistema, embora dada a limitação de poder de processamento do hardware embarcado utilizado neste projeto, opte-se por uma abordagem baseada primariamente em EAR/PERCLOS geométrico, reservando o uso de CNN como extensão futura condicionada à disponibilidade de tempo e capacidade computacional. De forma correlata, Ranjan et al. [Ranjan et al. 2020] propõem um sistema semelhante de detecção via EAR e classificador SVM (Support Vector Machine), utilizando a biblioteca *dlib* para localização de 68 pontos faciais de referência, evidenciando a viabilidade de execução em tempo real com baixo custo computacional adicional,

característica central para a escolha da abordagem geométrica (EAR/PERCLOS) adotada neste projeto em detrimento de modelos baseados unicamente em redes neurais profundas.

Do ponto de vista histórico e da fundamentação da métrica PERCLOS, o trabalho pioneiro de Grace et al. [Grace et al. 1998], conduzido no Carnegie Mellon Research Institute, descreve o desenvolvimento de uma das primeiras câmeras dedicadas à medição de PERCLOS em veículos pesados, evidenciando desde então os desafios de segurança do sensoriamento visual sob variação de iluminação, uso de óculos e movimentação da cabeça do motorista, desafios que permanecem centrais na literatura atual e que motivam a adoção de múltiplas modalidades de sensoriamento complementares nesta proposta, em vez de depender exclusivamente da câmera.

A síntese desses cinco trabalhos evidencia um consenso na literatura: (i) nenhuma modalidade isolada de sensoriamento é suficientemente segura para todos os cenários de condução; (ii) sistemas híbridos/multimodais tendem a apresentar maior segurança ao custo de maior complexidade de sincronização e fusão de dados; e (iii) a calibração individualizada por motorista (*baseline*) é apontada recorrentemente como estratégia para mitigar a variabilidade individual dos sinais fisiológicos e comportamentais. Esses três pontos fundamentam diretamente as decisões de projeto detalhadas na Seção 3.

No que tange à abrangência das áreas exigidas para este trabalho, a proposta envolve diretamente **Arquitetura de Computadores**, no projeto do pipeline de aquisição, condicionamento e fusão de sinais provenientes de múltiplos periféricos (câmera via CSI/USB, ADC externo via SPI/I2C para o sensor de força, e rádio BLE para o *smartwatch*), bem como na análise de desempenho computacional e consumo energético do nó de processamento (Raspberry Pi); e **Redes de Computadores**, no projeto da comunicação distribuída entre os dispositivos periféricos e o nó central, e deste com um painel remoto de monitoramento, utilizando um protocolo de mensageria leve orientado a publicação/assinatura (MQTT), com avaliação de latência, taxa de transmissão e escalabilidade.

3. Metodologia de Desenvolvimento e Avaliação

3.1. Arquitetura Proposta

O sistema é organizado em três módulos de aquisição distribuídos e um nó central de processamento:

- **Módulo visual**: câmera conectada ao Raspberry Pi, responsável pelo cálculo do EAR e do PERCLOS a partir de pontos de referência faciais;
- **Módulo fisiológico**: *smartwatch* comercial, conectado via Bluetooth Low Energy, do qual são extraídos a frequência cardíaca instantânea e quando disponível, indicadores derivados de variabilidade cardíaca (HRV);
- **Módulo mecânico**: sensor FSR fixado ao volante, condicionado por um circuito divisor de tensão e lido por um conversor analógico-digital externo (ADC), fornecendo a força de aperto aplicada pelo motorista;
- **Nó de fusão e decisão**: Raspberry Pi, responsável por sincronizar temporalmente os três fluxos de dados, aplicar o algoritmo de ponderação calibrado por motorista, disparar alertas locais (sonoro/visual) e publicar os dados e o estado de alerta via protocolo MQTT para um painel remoto de monitoramento.

3.2. Estado Atual da Implementação e Ajustes em Relação à Proposta

Conforme previsto no método de avaliação, esta subseção registra o protótipo efetivamente implementado até o momento e as diferenças em relação à arquitetura proposta. O protótipo atual integra três etapas: (i) leituras de frequência cardíaca (BPM) obtidas pelo telefone e enviadas a um servidor na rede local; (ii) análise de vídeo para detecção de sinais visuais de sonolência; e (iii) acionamento de um alerta físico por meio de um microcontrolador ESP32. A integração ocorre em um computador que executa o servidor de BPM e o detector de vídeo. O fluxo implementado é resumido a seguir:

1. Sensor vestível ou aplicativo de saúde grava leituras de frequência cardíaca no provedor de saúde do telefone (Health Connect, no Android);
2. Aplicativo Flutter consulta essas leituras, mantém histórico local em SQLite e as envia por WebSocket ao computador;
3. Servidor Python WebSocket armazena o histórico em SQLite e encaminha as leituras ao detector;
4. Detector de vídeo, com câmera conectada ao computador e MediaPipe Face Landmarker, calcula o estado de sonolência e exibe sobre o vídeo o BPM atual e sua tendência;
5. O estado de sonolência é enviado via USB/serial ao ESP32, que aciona um LED e um buzzer.

3.2.1. Aquisição do BPM

O aplicativo Flutter não mede os batimentos diretamente nem acessa o sensor óptico do relógio. Em vez da conexão BLE direta prevista na proposta, ele consulta dados de frequência cardíaca já registrados no provedor de saúde do telefone, por meio da biblioteca *health*, que no Android corresponde ao Health Connect. A leitura depende, portanto, de uma origem que grave dados nesse provedor (um relógio ou outro aplicativo compatível) e da permissão de leitura de `HEART_RATE` concedida ao aplicativo.

Após a autorização, o aplicativo realiza uma sincronização inicial das últimas 24 horas e, em seguida, sincronizações periódicas com intervalo padrão de 10 segundos, utilizando um *token* de alterações do provedor para incluir novos registros e refletir exclusões. Os registros são deduplicados, filtrados para valores numéricos de frequência cardíaca e ordenados do mais recente para o mais antigo. Ressalta-se que esse intervalo corresponde à frequência de consulta do aplicativo, e não à taxa de amostragem do sensor nem a uma transmissão batimento a batimento.

Antes do envio, as leituras são armazenadas em SQLite no próprio telefone, com BPM, horário, origem, identificador do registro e um indicador de envio. A cada sincronização, o aplicativo envia os registros ainda não transmitidos e as cinco leituras mais recentes do histórico, o que permite ao detector recuperar uma janela recente após conexão ou reconexão. Caso o servidor esteja indisponível, as leituras permanecem armazenadas localmente e são reenviadas posteriormente.

3.2.2. Comunicação em Rede

Em lugar do MQTT, a comunicação implementada entre o telefone e o computador utiliza WebSocket na porta 8765 da rede local. Cada leitura é transmitida como um objeto JSON contendo o horário em milissegundos (`ts`) e em formato ISO 8601 (`timestamp`), o BPM arredondado para inteiro (`bpm`), a origem (`source`), o identificador do registro (`health_uuid`) e um campo de intervalos RR (`rr`), atualmente enviado vazio.

O servidor Python escuta em todas as interfaces do computador, valida os registros recebidos, persiste o histórico em SQLite e encaminha as mensagens aos demais clientes conectados. O detector conecta-se ao servidor por uma conexão WebSocket separada e, ao conectar, solicita as cinco leituras mais recentes; em seguida, recebe as novas leituras à medida que chegam. Se o servidor não estiver disponível, o detector continua operando sem BPM e tenta reconectar periodicamente.

Com cinco amostras válidas, o detector calcula uma tendência simples comparando as medianas da parte mais antiga e da parte mais recente da janela: variação de pelo menos 5% é classificada como "subindo", de no máximo -5% como "caindo" e as demais como "estável". Trata-se de um indicador de tendência, e não de uma classificação clínica ou de uma estimativa de HRV.

3.2.3. Módulo Visual

A captura de vídeo é feita pelo OpenCV a partir de uma câmera conectada ao computador. Cada quadro é espelhado, convertido de BGR para RGB e processado pelo MediaPipe Face Landmarker, configurado para vídeo e para no máximo um rosto. O sistema não realiza identificação do motorista: os marcos faciais são utilizados apenas para medir sinais associados à sonolência:

- **EAR**: quando o valor médio permanece abaixo de 0,21 por pelo menos 1,5 s, o estado passa a ser considerado sonolento;
- **MAR (abertura da boca)**: quando ultrapassa 0,60 por pelo menos 0,55 s, um bocejo é contabilizado. O contador é exibido, mas não aciona o alerta físico;
- **Ausência de rosto**: o sistema indica que nenhum rosto foi detectado e reinicia os temporizadores de olhos fechados e bocejo.

Os quadros são processados localmente no computador e não são transmitidos pela rede.

3.2.4. Alerta Físico com ESP32

Um programa Python faz a ponte entre o detector e o ESP32 por meio de comunicação USB/serial a 115200 baud. A cada mudança de estado, envia a mensagem `1` quando há sonolência e `0` caso contrário, limitado a no máximo uma mensagem por segundo. No firmware, o ESP32 acende um LED (GPIO 17) e gera um tom de 2 kHz em um buzzer (GPIO 16) apenas quando recebe exatamente `1`; para qualquer outra mensagem, desliga ambos. Essa ligação serial é independente da comunicação WebSocket usada para o BPM.

3.2.5. Diferenças em Relação à Proposta

A Tabela 1 sintetiza as diferenças entre a arquitetura proposta e o protótipo atual.

Tabela 1. Arquitetura proposta *versus* protótipo implementado

Aspecto	Proposta	Protótipo atual
Aquisição de BPM	BLE direto com o *smartwatch*	Health Connect via aplicativo Flutter, sincronização a cada 10 s
Variabilidade cardíaca	HRV quando disponível	Não disponível (campo RR vazio); apenas tendência de BPM
Comunicação	MQTT (publicação/assinatura)	WebSocket na rede local (BPM) e USB/serial (alerta)
Nó de processamento	Raspberry Pi	Computador que executa servidor e detector
Decisão de alerta	Fusão ponderada das três modalidades	Apenas estado visual (EAR); BPM é informativo
Alerta local	Sonoro/visual	LED e buzzer no ESP32
Módulo mecânico	Sensor FSR no volante	Ainda não integrado ao fluxo

A adoção do Health Connect contorna a principal limitação prevista para o módulo fisiológico, isto é, o possível acesso restrito ao protocolo Bluetooth proprietário do relógio, ao custo de uma latência dependente da sincronização do provedor de saúde e da ausência de intervalos RR. As etapas pendentes, que incluem a integração do sensor FSR, a implementação do algoritmo de fusão com calibração por motorista e a migração do processamento para o Raspberry Pi, permanecem previstas no cronograma.

3.3. Processo de Desenvolvimento

O desenvolvimento contempla as quatro frentes previstas nos requisitos da disciplina: (i) **programação e implementação de software**, no desenvolvimento do pipeline de visão computacional, do cliente BLE para leitura do *smartwatch*, da leitura do ADC e do algoritmo de fusão; (ii) **descrição de hardware**, no projeto do circuito de condicionamento do sensor FSR (divisor de tensão e escolha do resistor fixo); (iii) **configuração de cenário de simulação**, na simulação de múltiplos nós/motoristas via publicação MQTT sintética para avaliação de escalabilidade de rede; e (iv) **experimentação prática**, na coleta real de dados fisiológicos, visuais e mecânicos com voluntários.

3.4. Método de Avaliação e Validação

Adota-se um **modelo de medição experimental**, por meio de protótipo funcional e coleta de métricas reais, dividido em três camadas:

- **Camada algorítmica (detecção)**: acurácia, precisão, revocação (*recall*) e F1-*score* do algoritmo de fusão, calculados a partir de um protocolo controlado de indução de sonolência simulada, com rótulo de referência (*ground truth*) definido por marcação temporal do protocolo experimental e, complementarmente, por autorrelato do voluntário via escala KSS;

- **Camada de sistema/arquitetura**: tempo de resposta entre a leitura do sensor e a tomada de decisão, uso de CPU e memória do Raspberry Pi durante a execução simultânea dos três fluxos de aquisição, e consumo energético (Watt/Joule), medido com sensor de corrente/tensão (por exemplo, INA219) conectado à alimentação do Raspberry Pi;
- **Camada de rede**: latência ponta a ponta entre a geração do alerta e sua chegada ao painel remoto, taxa de transmissão (mensagens/pacotes por segundo), taxa de perda de pacotes, e escalabilidade, avaliada por meio da simulação de múltiplos nós publicando dados simultaneamente via MQTT.

A escolha do modelo de medição, no lugar de um modelo puramente analítico ou de simulação computacional, justifica-se pela natureza do problema, que depende fortemente de sinais reais capturados de sensores físicos e de comportamento humano, cuja modelagem puramente teórica não capturaria adequadamente os fenômenos de ruído, artefato de movimento e variabilidade individual discutidos na Seção 2. Ainda assim, poderá ser incorporado um componente de simulação (publicação sintética de dados via MQTT) especificamente para a avaliação de escalabilidade de rede, complementando o modelo de medição principal. Eventuais ajustes a este método, motivados por limitações de hardware ou de tempo, serão registrados e justificados ao longo do desenvolvimento, conforme orientação da disciplina.

3.5. Cronograma de Atividades

O cronograma proposto, organizado em base quinzenal, está apresentado na Tabela 2.

Tabela 2. Cronograma de atividades

Período	Atividades
Semanas 1–2	Revisão bibliográfica; definição final da arquitetura; testes de viabilidade do protocolo BLE do *smartwatch* disponível.
Semanas 3–4	Montagem do circuito do sensor FSR (divisor de tensão, ADC) e calibração estática com pesos conhecidos.
Semanas 5–6	Implementação do módulo de visão (EAR/PERCLOS) no Raspberry Pi.
Semanas 7–8	Implementação do cliente BLE de leitura do *smartwatch* e integração dos três fluxos de dados no nó central.
Semanas 9–10	Implementação do algoritmo de fusão ponderada e da etapa de calibração/*baseline* por motorista.
Semanas 11–12	Implementação da camada de rede (publicação MQTT, painel remoto) e cenário de simulação para escalabilidade.
Semanas 13–14	Execução dos experimentos de coleta de dados com voluntários, consolidação dos resultados, cálculo das métricas, análise crítica e redação final do artigo.

4. Definição do Tema, Delimitação e Limitações

O objeto de estudo deste trabalho é a detecção antecipada de sonolência de motoristas por meio de um sistema embarcado de baixo custo, fundamentado na fusão de sinais visuais,

fisiológicos (via *smartwatch* comercial) e mecânicos (força de aperto no volante). O problema é delimitado ao contexto de prova de conceito acadêmica, não se propondo, nesta etapa, a substituir sistemas certificados de segurança veicular e nem operar em veículo real em movimento nas condições finais de avaliação. Os experimentos serão conduzidos em ambiente controlado, com simulação comportamental da sonolência por parte dos voluntários.

Como limitações reconhecidas do trabalho, destacam-se: (i) a dependência do provedor de saúde do telefone (Health Connect) para obtenção do BPM, adotado como alternativa ao acesso BLE direto ao *smartwatch*, o que sujeita a atualização dos dados ao intervalo de sincronização do aplicativo e à frequência com que o relógio grava leituras no provedor, além de não fornecer intervalos RR, impossibilitando, na configuração atual, o cálculo de HRV; (ii) o tamanho reduzido da amostra de voluntários, compatível com o escopo de uma disciplina, o que limita a generalização estatística dos resultados; (iii) a suscetibilidade do sinal de PPG a artefatos de movimento durante a condução, meta a ser mitigada por meio de filtragem digital mas não eliminada por completo; (iv) a ausência de validação em condições reais de tráfego, com os experimentos restritos a ambiente controlado e simulação comportamental; e (v) a dependência de uma etapa de calibração individual por motorista, o que implica que o desempenho do sistema para motoristas não previamente calibrados poderá ser inferior ao observado nos testes com calibração prévia.

5. Considerações Finais

Esta proposta apresenta um sistema de detecção de sonolência veicular fundamentado na fusão de três modalidades de sensoriamento complementares, processadas em um Raspberry Pi e distribuídas por meio de comunicação em rede, atendendo aos requisitos de abrangência de áreas (Arquitetura de Computadores e Redes de Computadores), de desenvolvimento (implementação de software, descrição de hardware e experimentação prática) e de validação (modelo de medição experimental com métricas de acurácia, desempenho e rede) estabelecidos pela disciplina. O protótipo atual já integra a aquisição de BPM via Health Connect, a transmissão por WebSocket, a detecção visual de sonolência e o alerta físico por ESP32. Os próximos passos consistem na integração do sensor de força de aperto, na implementação do algoritmo de fusão com calibração por motorista, na migração do processamento para o Raspberry Pi e na execução dos experimentos descritos no método de avaliação.

Referências

Grace, R., Byrne, V. E., Bierman, D. M., Legrand, J.-M., Gricourt, D., Davis, R. K., Staszewski, J. J., and Carnahan, B. (1998). A drowsy driver detection system for heavy vehicles. In *Proceedings of the 17th DASC. AIAA/IEEE/SAE. Digital Avionics Systems Conference*. IEEE.

Ma'ajid, F. R. and Al-Khowarizmi (2025). Implementation of a drowsiness detection system in four-wheel vehicle drivers using opencv. *Electronic Integrated Computer Algorithm Journal*, 3(1):28–32.

Peker, N. Y., Peker, E., and Zengin, A. (2026). A comparative review of driver drowsiness detection systems: Recent advances, applications, challenges, and future directions. *Measurement*, 279:121676.

Ranjan, A., Vyas, K., Ghadge, S., Patel, S., and Pawar, S. S. (2020). Driver drowsiness detection system using computer vision. *International Research Journal of Engineering and Technology (IRJET)*, 7(1):1555–1559.

Sahmarany, L. E., Alkhaldi, M., and Alzahrani, S. I. (2026). Sensing technologies and physiological parameters for real-time driver drowsiness detection: A comprehensive review. *Sensors*, 26(11):3333.