PONTIFÍCIA UNIVERSIDADE CATÓLICA DE MINAS GERAIS
Instituto de Ciências Exatas e Informática
Disciplina: Inteligência Artificial
Prof. Gabriel Pereira de Oliveira

Lista de Exercícios #2 – Árvores de Decisão
Valor: 2 pontos

Esta lista de exercícios é baseada nos assuntos discutidos em aula e no conteúdo dos seguintes slides disponibilizados no CANVAS:

- *3 - Árvores de Decisão*
- *4 - Árvores de Decisão - Como Calcular*
- *5 - Árvores de Decisão - Métricas de avaliação*

A entrega deverá ser realizada em um arquivo em formato PDF na respectiva tarefa do CANVAS.

Questão 01. Sobre os conceitos de Árvores de Decisão, responda:

1. Como uma árvore de decisão é gerada? Qual o significado do atributo que está na raiz da árvore?
   Uma árvore de decisão é gerada através de um processo de divisão recursiva do conjunto de dados (estratégia "dividir para conquistar"), onde o algoritmo seleciona em cada passo o atributo que melhor separa as classes. O atributo na raiz é aquele considerado o mais importante (com maior poder discriminatório ou ganho de informação) para o problema.
2. Qual a diferença entre os nós internos e os nós de folha de uma árvore de decisão?
   Nós internos representam testes em atributos específicos de entrada, enquanto os nós de folha representam a decisão final ou a classe (rótulo) a ser atribuída à instância.
3. O que você pode fazer com uma árvore de decisão gerada a partir de uma base de dados?
   Ela pode ser usada para predição (classificar novos dados) e para a descoberta de conhecimento, permitindo entender a lógica por trás das decisões do modelo.
4. Quais as principais vantagens e desvantagens de um algoritmo de árvore de decisão?
   As principais vantagens incluem flexibilidade, interpretabilidade, cobertura exaustiva do espaço de instâncias, são modelos robustos contra a adição de atributos irrelevantes, dentre outras. Já as desvantagens incluem a necessidade de mecanismos especiais para falta de valores e atributos contínuos, além da instabilidade relacionada a pequenas variações no conjunto de treinamento (podem alterar fortemente a árvore final).
5. Como avaliamos a qualidade de uma árvore?
   A qualidade da árvore pode ser avaliada em relação à sua capacidade de separar as instâncias de acordo com as classes (se estamos falando de classificação). Mais especificamente, podemos empregar métricas como acurácia, precisão, recall e F1-score, que são obtidas por meio de matrizes de confusão.

6. Como podemos obter as regras a partir de uma árvore de decisão?

   As regras são obtidas percorrendo cada caminho da raiz até uma folha, onde cada nó interno vira uma condição SE e a folha vira a conclusão ENTÃO.

Questão 02. Considere o conjunto de dados sobre "Esperar ou não pelo restaurante" (verifique o arquivo **"restaurante.csv"** no CANVAS) e faça:

1. Calcule o ganho de informação para cada atributo. Qual será o atributo raiz da árvore?

   Fórmula da entropia de um conjunto (variável-alvo):

$$H(V) = -\sum_{k} P(v_k)\log_2 P(v_k)$$

   Fórmula da entropia de um atributo que divide um conjunto em *d* subconjuntos:

$$H(atributo) = \sum_{k=1}^{d} \frac{p_k + n_k}{p + n} H(E_k)$$

   Fórmula do ganho de informação:

$$ganho(atributo) = H(alvo) - H(atributo)$$

Alternativo	Bar	SexSab	fome	Cliente	Preco	Chuva	Res	Tipo	Tempo	Conclusao
Sim	Nao	Nao	Sim	Alguns	RRR	Nao	Sim	Frances	0-10	Sim
Sim	Nao	Nao	Sim	Cheio	R	Nao	Nao	Tailandes	30-60	Nao
Nao	Sim	Nao	Nao	Alguns	R	Nao	Nao	Hamburger	0-10	Sim
Sim	Nao	Sim	Sim	Cheio	R	Sim	Nao	Tailandes	10-30	Sim
Sim	Nao	Sim	Nao	Cheio	RRR	Nao	Sim	Frances	>60	Nao
Nao	Sim	Nao	Sim	Alguns	RR	Sim	Sim	Italiano	0-10	Sim
Nao	Sim	Nao	Nao	Nenhum	R	Sim	Nao	Hamburger	0-10	Nao
Nao	Nao	Nao	Sim	Alguns	RR	Sim	Sim	Tailandes	0-10	Sim
Nao	Sim	Sim	Nao	Cheio	R	Sim	Nao	Hamburger	>60	Nao
Sim	Sim	Sim	Sim	Cheio	RRR	Nao	Sim	Italiano	10-30	Nao
Nao	Nao	Nao	Nao	Nenhum	R	Nao	Nao	Tailandes	0-10	Nao
Sim	Sim	Sim	Sim	Cheio	R	Nao	Nao	Hamburger	30-60	Sim

Variável-alvo: Conclusao

Atributos: Alternativo, Bar, SexSab, fome, Cliente, Preco, Chuva, Res, Tipo, Tempo

Passo 1: calcular a entropia do conjunto total (variável-alvo/target)

Sim: 6 exemplos → probabilidade = 6/12 = 1/2

Não: 6 exemplos → probabilidade = 6/12 = 1/2

H(Conclusao) = - (1/2 * log2(1/2) + 1/2 * log2(1/2))
= - (1/2 * (-1) + 1/2 * (-1))
= 1

Passo 2: calcular o ganho de informação de cada atributo que divide o conjunto em vários subconjuntos

- **Alternativa** divide em dois subconjuntos
  - **Alternativa=Sim**, com 6 instâncias de 12 → tamanho relativo 6/12
    - Dessas 6 instâncias (Alternativa=Sim)
      - Em 3 delas, Conclusão=Sim → probabilidade = 3/6
      - Em 3 delas, Conclusão=Não → probabilidade = 3/6
  - **Alternativa=Não**, com 6 instâncias de 12 → tamanho relativo 6/12
    - Dessas 6 instâncias (Alternativa=Não)
      - Em 3 delas, Conclusão=Sim → probabilidade = 3/6
      - Em 3 delas, Conclusão=Não → probabilidade = 3/6

H(Alternativa) = 6/12 H(Sim) + 6/12 H(Não)
= 6/12 [- (3/6 * log2(3/6) + 3/6 * log2(3/6))]
+ 6/12 [- (3/6 * log2(3/6) + 3/6 * log2(3/6))]
= 1

Ou seja, o meu ganho de informação para o atributo Alternativa será:

ganho(Alternativa) = H(Conclusao) - H(Alternativa)
= 1 - 1
= 0

- **Bar** divide em dois subconjuntos
  - **Bar=Sim**, com 6 instâncias de 12 → tamanho relativo 6/12
    - Dessas 6 instâncias (Bar=Sim)
      - Em 3 delas, Conclusão=Sim → probabilidade = 3/6
      - Em 3 delas, Conclusão=Não → probabilidade = 3/6
  - **Bar=Não**, com 6 instâncias de 12 → tamanho relativo 6/12
    - Dessas 6 instâncias (Bar=Não)
      - Em 3 delas, Conclusão=Sim → probabilidade = 3/6
      - Em 3 delas, Conclusão=Não → probabilidade = 3/6

H(Bar) = 6/12 H(Sim) + 6/12 H(Não)
= 6/12 [- (3/6 * log2(3/6) + 3/6 * log2(3/6))]
+ 6/12 [- (3/6 * log2(3/6) + 3/6 * log2(3/6))]
= 1

Ou seja, o meu ganho de informação para o atributo Bar será:

ganho(Bar) = H(Conclusao) - H(Bar)
= 1 - 1
= 0

- **SexSab** divide em dois subconjuntos
  - **SexSab=Sim**, com 5 instâncias de 12 → tamanho relativo 5/12
    - Dessas 5 instâncias (**SexSab**=Sim)
      - Em 2 delas, Conclusão=Sim → probabilidade = 2/5
      - Em 3 delas, Conclusão=Não → probabilidade = 3/5
  - **SexSab=Não**, com 7 instâncias de 12 → tamanho relativo 7/12
    - Dessas 7 instâncias (**SexSab**=Não)
      - Em 4 delas, Conclusão=Sim → probabilidade = 4/7
      - Em 3 delas, Conclusão=Não → probabilidade = 3/7

H(**SexSab**) = 5/12 H(Sim) + 7/12 H(Não)
= 5/12 [- (2/5 * log2(2/5) + 3/5 * log2(3/5))]
+ 7/12 [- (4/7 * log2(4/7) + 3/7 * log2(3/7))]
= 0.979

Ou seja, o meu ganho de informação para o atributo SexSab será:

ganho(**SexSab**) = H(Conclusao) - H(SexSab)
= 1 - 0.979
= 0.021

- **Fome** divide em dois subconjuntos
  - **Fome=Sim**, com 7 instâncias de 12 → tamanho relativo 7/12
    - Dessas 7 instâncias (**Fome**=Sim)
      - Em 5 delas, Conclusão=Sim → probabilidade = 5/7
      - Em 2 delas, Conclusão=Não → probabilidade = 2/7
  - **Fome=Não**, com 5 instâncias de 12 → tamanho relativo 5/12
    - Dessas 5 instâncias (**Fome**=Não)
      - Em 1 delas, Conclusão=Sim → probabilidade = 1/5
      - Em 4 delas, Conclusão=Não → probabilidade = 4/5

H(**Fome**) = 7/12 H(Sim) + 5/12 H(Não)
= 7/12 [- (5/7 * log2(5/7) + 2/7 * log2(2/7))]
+ 5/12 [- (1/5 * log2(1/5) + 4/5 * log2(4/5))]
= 0.804

Ou seja, o meu ganho de informação para o atributo Fome será:

ganho(**Fome**) = H(Conclusao) - H(Fome)

= 1 - 0.804

= 0.196

- **Clientes** divide em três subconjuntos
  - **Clientes=Alguns**, com 4 instâncias de 12 → tamanho relativo 4/12
    - Dessas 4 instâncias (**Clientes=Alguns**)
      - Em 4 delas, Conclusão=Sim → probabilidade = 4/4 = 1
      - Em 0 delas, Conclusão=Não → probabilidade = 0/4 = 0
  - **Clientes=Nenhum**, com 2 instâncias de 12 → tamanho relativo 2/12
    - Dessas 2 instâncias (**Clientes=Nenhum**)
      - Em 0 delas, Conclusão=Sim → probabilidade = 0/2 = 0
      - Em 2 delas, Conclusão=Não → probabilidade = 2/2 = 1
  - **Clientes=Cheio**, com 6 instâncias de 12 → tamanho relativo 6/12
    - Dessas 6 instâncias (**Clientes=Nenhum**)
      - Em 2 delas, Conclusão=Sim → probabilidade = 2/6
      - Em 4 delas, Conclusão=Não → probabilidade = 4/6

H(**Clientes**) = 4/12 H(Alguns) + 2/12 H(Nenhum) + 6/12 H(Cheio)

= 4/12 [- (1 * log2(1) + 0 * log2(0))]

+ 2/12 [- (0* log2(0) + 1 * log2(1))]

+ 6/12 [- (2/6 * log2(2/6) + 4/6 * log2(4/6))]

= 0.459

Ou seja, o meu ganho de informação para o atributo Clientes será:

ganho(**Clientes**) = H(Conclusao) - H(Clientes)

= 1 - 0.459

= 0.541

Aplicando o mesmo raciocínio para os outros atributos, temos:

- ganho(**Preço**) = 0.196
- ganho(**Chuva**) = 0.021
- ganho(**Res**) = 0.021
- ganho(**Tipo**) = 0
- ganho(**Tempo**) = 0.208

Passo 3: A raiz da árvore será o atributo com o maior ganho de informação. Sendo assim, escolhemos como raiz o atributo **Clientes**.

2. Qual atributo estará no segundo nível da árvore? Faça os cálculos e apresente a árvore gerada até o segundo nível.

   Como a raiz da árvore é Clientes, temos:

   - Clientes=Nenhum → NÃO
   - Clientes=Alguns → SIM
   - Se Cliente=Cheio, os dados ainda não estão puros. Então, precisamos descer mais um nível na árvore → 2º nível.

Agora, nosso conjunto de instâncias foi reduzido a um novo subproblema contendo apenas as linhas onde Cliente=Cheio. Além disso, não precisamos mais de considerar a coluna Cliente em nosso cálculo de ganho de informação, pois ele já foi usado na raiz.

Alternativo	Bar	SexSab	fome	Preco	Chuva	Res	Tipo	Tempo	Conclusao
Sim	Nao	Nao	Sim	R	Nao	Nao	Tailandes	30-60	Nao
Sim	Nao	Sim	Sim	R	Sim	Nao	Tailandes	10-30	Sim
Sim	Nao	Sim	Nao	RRR	Nao	Sim	Frances	>60	Nao
Nao	Sim	Sim	Nao	R	Sim	Nao	Hamburger	>60	Nao
Sim	Sim	Sim	Sim	RRR	Nao	Sim	Italiano	10-30	Nao
Sim	Sim	Sim	Sim	R	Nao	Nao	Hamburger	30-60	Sim

Dado esse novo conjunto de dados (contendo 6 instâncias), basta repetir o procedimento realizado no exercício anterior:

Variável-alvo: Conclusao
Atributos: Alternativo, Bar, SexSab, fome, Preco, Chuva, Res, Tipo, Tempo

Passo 1: calcular a entropia do conjunto total (variável-alvo/target)
Sim: 2 exemplos → probabilidade = 2/6
Não: 4 exemplos → probabilidade = 4/6

H(Conclusao) = - (2/6 * log2(2/6) + 4/6 * log2(4/6))
= 0.918

Passo 2: calcular o ganho de informação de cada atributo que divide o conjunto em vários subconjuntos

- **Alternativa** divide em dois subconjuntos
  - **Alternativa=Sim**, com 5 instâncias de 6 → tamanho relativo 5/6
    - Dessas 5 instâncias (Alternativa=Sim)
      - Em 2 delas, Conclusão=Sim → probabilidade = 2/5

            - Em 3 delas, Conclusão=Não → probabilidade = 3/5
    - **Alternativa=Não**, com 1 instância de 6 → tamanho relativo 1/6
        - Dessas 1 instâncias (Alternativa=Não)
            - Em 0 delas, Conclusão=Sim → probabilidade = 0/6 = 0
            - Em 1 delas, Conclusão=Não → probabilidade = 1/1 = 1

H(Alternativa) = 5/6 H(Sim) + 1/6 H(Não)
= 5/6 [- (2/5 * log2(2/5) + 3/5 * log2(3/5))]
+ 1/6 [- (0 * log2(0) + 1 * log2(1))]
= 0.809

Ou seja, o meu ganho de informação para o atributo Alternativa será:

ganho(Alternativa) = H(Conclusao) - H(Alternativa)
= 0.918 - 0.809
= 0.109

- **Bar** divide em dois subconjuntos
    - **Bar=Sim**, com 3 instâncias de 6 → tamanho relativo 3/6
        - Dessas 3 instâncias (Bar=Sim)
            - Em 1 delas, Conclusão=Sim → probabilidade = 1/3
            - Em 2 delas, Conclusão=Não → probabilidade = 2/3
    - **Bar=Não**, com 3 instâncias de 6 → tamanho relativo 3/6
        - Dessas 3 instâncias (Bar=Não)
            - Em 1 delas, Conclusão=Sim → probabilidade = 1/3
            - Em 2 delas, Conclusão=Não → probabilidade = 2/3

H(Bar) = 3/6 H(Sim) + 3/6 H(Não)
= 3/6 [- (1/3 * log2(1/3) + 2/3 * log2(2/3))]
+ 3/6 [- (1/3 * log2(1/3) + 2/3 * log2(2/3))]
= 0.918

Ou seja, o meu ganho de informação para o atributo Bar será:

ganho(Bar) = H(Conclusao) - H(Bar)
= 0.918 - 0.918
= 0

- **SexSab** divide em dois subconjuntos
    - **SexSab=Sim**, com 5 instâncias de 6 → tamanho relativo 5/6
        - Dessas 5 instâncias (**SexSab**=Sim)
            - Em 2 delas, Conclusão=Sim → probabilidade = 2/5
            - Em 3 delas, Conclusão=Não → probabilidade = 3/5
    - **SexSab=Não**, com 1 instâncias de 6 → tamanho relativo 1/6

        - Dessas 1 instâncias (**SexSab**=Não)
            - Em 0 delas, Conclusão=Sim → probabilidade = 0
            - Em 1 delas, Conclusão=Não → probabilidade = 1

H(**SexSab**) = 5/6 H(Sim) + 1/6 H(Não)
= 5/6 [- (2/5 * log2(2/5) + 3/5 * log2(3/5))]
+ 1/6 [- (0 * log2(0) + 1 * log2(1))]
= 0.809

Ou seja, o meu ganho de informação para o atributo SexSab será:

ganho(**SexSab**) = H(Conclusao) - H(SexSab)
= 0.918 - 0.809
= 0.109

- **Fome** divide em dois subconjuntos
    - **Fome=Sim**, com 4 instâncias de 6 → tamanho relativo 4/6
        - Dessas 4 instâncias (**Fome**=Sim)
            - Em 2 delas, Conclusão=Sim → probabilidade = 2/4
            - Em 2 delas, Conclusão=Não → probabilidade = 2/4
    - **Fome=Não**, com 2 instâncias de 6 → tamanho relativo 2/6
        - Dessas 2 instâncias (**Fome**=Não)
            - Em 0 delas, Conclusão=Sim → probabilidade = 0
            - Em 2 delas, Conclusão=Não → probabilidade = 1

H(**Fome**) = 4/6 H(Sim) + 2/6 H(Não)
= 4/6 [- (2/4 * log2(2/4) + 2/4 * log2(2/4))]
+ 2/6 [- (0 * log2(0) + 1 * log2(1))]
= 0.667

Ou seja, o meu ganho de informação para o atributo Fome será:

ganho(**Fome**) = H(Conclusao) - H(Fome)
= 0.918 - 0.667
= 0.251

Aplicando o mesmo raciocínio para os outros atributos, temos:

- ganho(**Preço**) = 0.251
- ganho(**Chuva**) = 0.251
- ganho(**Res**) = 0.251
- ganho(**Tipo**) = 0.251
- ganho(**Tempo**) = 0.251

Passo 3. A raiz da árvore será o atributo com o maior ganho de informação. Como todos empataram, posso escolher qualquer um deles. Nesta resolução, escolhi **Fome**. A árvore então fica dessa forma:

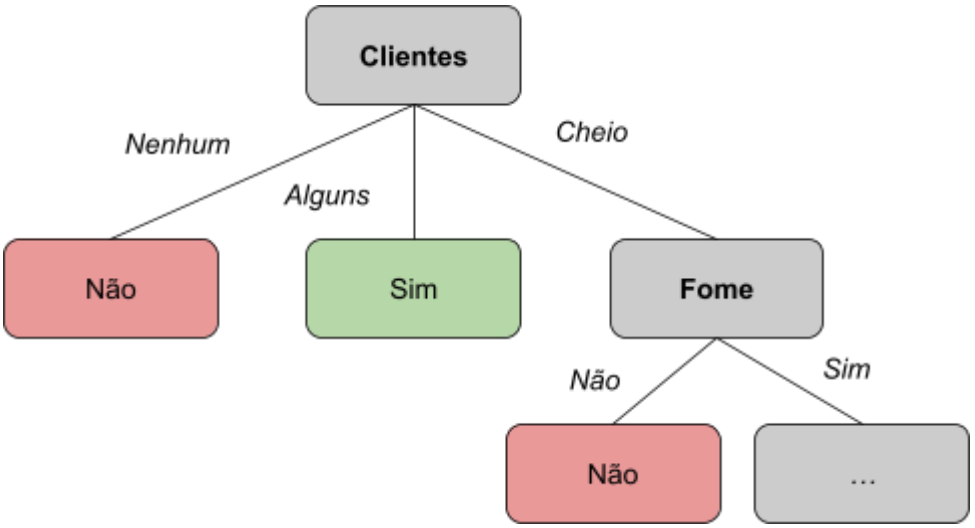

Questão 03. Leia o artigo **"A comparative study of decision tree ID3 and C4.5"** que está no CANVAS e responda:

1. Quais as diferenças entre os algoritmos de árvore ID3 e C4.5?
   O C4.5 é uma evolução do ID3. Enquanto o ID3 usa o Ganho de Informação (que favorece atributos com muitos valores), o C4.5 utiliza a Razão de Ganho (Gain Ratio). Além disso, o C4.5 suporta poda de árvore (*pruning*), lida com valores ausentes e aceita atributos numéricos.
2. Como o algoritmo C4.5 lida com os atributos de entrada que são numéricos?
   O C4.5 lida com atributos contínuos criando limiares e faz a divisão de acordo com eles (valor <= limiar ou valor > limiar). Ele ordena os valores e testa todos os pontos de corte possíveis para encontrar o que maximiza o ganho de informação.

Questão 04. A figura abaixo mostra uma árvore de decisão construída a partir de um conjunto de dados no qual as instâncias são descritas por quatro atributos: **(i) Tamanho da Pétala, (ii) Largura da Pétala, (iii) Tamanho da Sépala e (iv) Largura da Sépala**.

Cada instância, por sua vez, pertence a uma das quatro classes: **Iris_Setosa**, **Iris_Virgínica** e **Iris_Versicolor**. Esta árvore foi gerada em linguagem Python com os hiperparâmetros (DecisionTreeClassifier(criterion='gini', max_depth=3)).

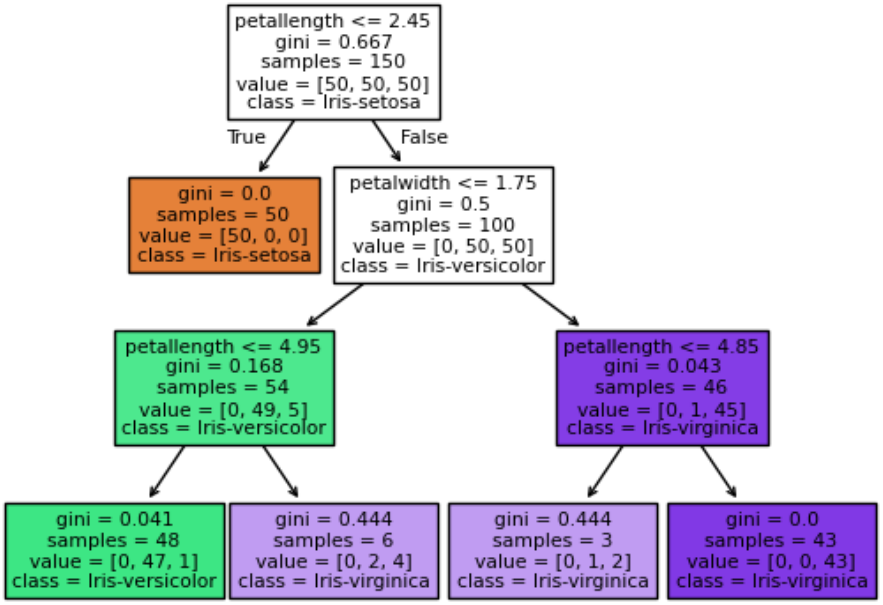

Observação: *Caso tenha curiosidade de saber como esta árvore foi construída, veja o código "decision_tree_iris.ipynb" disponível no CANVAS.*

Com base nestas informações, quais serão as saídas da árvore (classes preditas) para os seguintes **registros de teste**?

ID	**Tamanho da Pétala (*petallength*)**	**Largura da Pétala (*petalwidth*)**	**Tamanho da Sépala (*sepallength*)**	**Largura da Sépala (*sepalwidth*)**	**Classe**
1	3.46	0.87	2.45	1.78	iris-versicolor
2	1.67	1.89	0.78	1.32	iris-setosa
3	2.56	2.34	0.78	1.78	iris-virginica
4	6.67	2.34	2.45	1.78	iris-virginica

Questão 05. Considere a seguinte matriz de confusão obtida para o problema do restaurante (i.e., o objetivo era decidir se espero uma mesa em um restaurante) por meio de uma Árvore de Decisão:

		Classe Predita	
	Vou esperar?	**SIM**	**NÃO**
Classe Verdadeira	**SIM**	15	3
	NÃO	5	10

Quais são os valores das métricas abaixo para cada uma das classes (SIM/NÃO)?

	TVP	TFN	TFP	TVN	Precisão	Recall	F1-Score
SIM	15/18	3/18	5/15	10/15	15/20	15/18	15/19
NÃO	10/15	5/15	3/18	15/18	10/13	10/15	5/7

Questão 06. Considere agora uma matriz de confusão obtida por meio de uma Árvore de Decisão para um problema genérico de classificação de quatro classes:

		Classe Predita			
		A	**B**	**C**	**C**
Classe Verdadeira	**A**	10	4	2	1
	B	1	15	2	0
	C	2	3	20	5
	D	4	1	2	50

Quais são os valores das métricas abaixo para cada uma das classes A, B, C e D?

	TVP	TFN	TFP	TVN	Precisão	Recall	F1-Score
A	10/17	7/17	7/105	98/105	10/17	10/17	10/17
B	15/18	3/18	8/104	96/104	15/23	15/18	30/41
C	20/30	10/30	6/92	86/92	20/26	20/30	5/7
D	50/57	7/57	6/65	59/65	50/56	50/57	100/113

TVP (Taxa de Verdadeiros Positivos) = VP / (VP + FN)

- Dentre todos os positivos reais, quantos o modelo acertou?
- Quem era positivo na realidade e o modelo classificou como positivo

TFN (Taxa de Falsos Negativos) = FN / (VP + FN)

- Dentre todos os positivos reais, quantos o modelo errou?
- Quem era positivo na realidade e o modelo classificou como negativo

TFP (Taxa de Falsos Positivos) = FP / (FP / VN)

- Dentre todos os negativos reais, quantos o modelo classificou errado como positivo?
- Quem não pertencia a uma classe X e o modelo classificou como sendo da classe X?

TVN (Taxa de Verdadeiros Negativos) = VN / (FP / VN)

- Dentre todos os negativos reais, quantos o modelo classificou certo?
- Quem não pertencia a uma classe X e o modelo classificou como NÃO sendo da classe X?

Precisão = VP / (VP + FP)

- Taxa de instâncias corretamente classificadas como pertencentes a classe em questão dentre todos os que foram classificados na classe em questão.
- Dentre todo mundo que foi classificado como classe X, quem REALMENTE era da classe X?

Recall (sensibilidade) = VP / (VP + FN) = TVP

- Taxa de instâncias corretamente classificadas como pertencentes a classe em questão dentre todos os que realmente são da classe em questão.
- Dentre todo mundo que REALMENTE era da classe X, quem foi classificado como sendo X?

F1-Score = (2 * recall * precisão) / (recall + precisão)

- Média harmônica para recall e precisão