

Lista de Exercícios #2 – Árvores de Decisão

Aluno: Thiago Henrique Gomes Feliciano - 1543790

Questão 01. Sobre os conceitos de Árvores de Decisão, responda:

1. Como uma árvore de decisão é gerada? Qual o significado do atributo que está na raiz da árvore?

R:

- Começa com todo o conjunto de dados no nó inicial (raiz);
- O algoritmo testa cada atributo do conjunto de dados para descobrir qual deles separa melhor os exemplos em classes diferentes;
- O atributo que melhor separa os dados é escolhido para fazer a divisão;
- O conjunto de dados é então dividido em subconjuntos de acordo com os valores desse atributo;
- Para cada subconjunto, o processo é repetido recursivamente, criando novos nós.

Um atributo estar na raiz da árvore significa que ele é o atributo que melhor separa os dados no conjunto inteiro.

2. Qual a diferença entre os nós internos e os nós de folha de uma árvore de decisão?

R: Os nós internos testam um dos atributos de entrada, os nós de folhas são os valores que podem ser retornados.

3. O que você pode fazer com uma árvore de decisão gerada a partir de uma base de dados?

R: Pode se usar para classificação, previsão, extração de regras de decisão, ajudar a tomar decisões, análise e interpretação de dados.

4. Quais as principais vantagens e desvantagens de um algoritmo de árvore de decisão?

R: Suas principais vantagens são a sua flexibilidade, sua seleção de atributos(assim tirando atributos irrelevantes), interpretabilidade, eficiência. Suas principais desvantagens são sua não conseguir lidar com valores ausentes, tendo que usar mecanismos para empregar valores a eles, dificuldade de lidar com atributos contínuos, instabilidade(pequenas variações no conjunto de treinamento produzem grandes variações na árvore final).

5. Como avaliamos a qualidade de uma árvore?

R: Através do VP, VN, FP, FN, acurácia, precisão, sensibilidade (recall), F1-score.

6. Como podemos obter as regras a partir de uma árvore de decisão?

R: Para obter regras de uma árvore de decisão percorre-se cada caminho da raiz até uma folha, combinando as condições dos nós internos com “E”, a folha indica o resultado final da regra.

Questão 02. Considere o conjunto de dados sobre “Esperar ou não pelo restaurante” (verifique o arquivo “restaurante.csv” no CANVAS) e faça:

1. Calcule o ganho de informação para cada atributo. Qual será o atributo raiz da árvore?


R:

Alternativo: 0
Bar: 0
SexSab: 0,021
fome: 0,196
Cliente: 0,541
Preco: 0,196
Chuva: 0,02
Res: 0,021
Tipo: 0
Tempo: 0,21

O atributo raiz da árvore será “Cliente”, pois é o que traz mais informação.

2. Qual atributo estará no segundo nível da árvore? Faça os cálculos e apresente a árvore gerada até o segundo nível.

R: Será o atributo “Tempo”, pois depois do atributo “cliente” é o que mais dá ganho de informação.



Questão 03. Leia o artigo “A comparative study of decision tree ID3 and C4.5” que está no CANVAS e responda:

1. Quais as diferenças entre os algoritmos de árvore ID3 e C4.5?


R: O algoritmo C4.5 é uma extensão do ID3 e apresenta algumas melhorias importantes: Possibilidade de usar dados contínuos: C4.5 consegue trabalhar com atributos numéricos, dividindo os valores por limites (thresholds). Tratamento de valores desconhecidos: o algoritmo consegue lidar com dados ausentes (missing values) durante a construção da árvore. Uso de pesos para atributos: permite considerar diferentes importâncias entre atributos. Poda da árvore (pruning): após a construção da árvore, o C4.5 remove ramos que não contribuem significativamente para a classificação, reduzindo o overfitting.

2. Como o algoritmo C4.5 lida com os atributos de entrada que são numéricos?

R: O algoritmo C4.5 trata atributos numéricos analisando os valores contínuos presentes nos dados de treinamento. Primeiro, os valores do atributo são ordenados em ordem crescente ($A_1, A_2, \dots, A_m$). Em seguida, para cada valor possível A_j , o algoritmo cria uma divisão que separa os registros em dois grupos: valores menores ou iguais a A_j e valores maiores que A_j . Para cada divisão é calculado o information gain ou gain ratio, e a divisão que maximiza o ganho é escolhida para formar o nó da árvore de decisão.

Questão 04. A figura abaixo mostra uma árvore de decisão construída a partir de um conjunto de dados no qual as instâncias são descritas por quatro atributos: (i) Tamanho da Pétala, (ii) Largura da Pétala, (iii) Tamanho da Sépala e (iv) Largura da Sépala.

Cada instância, por sua vez, pertence a uma das quatro classes: Iris_Setosa, Iris_Virginica e Iris_Versicolor. Esta árvore foi gerada em linguagem Python com os hiperparâmetros (DecisionTreeClassifier(criterion='gini', max_depth=3)).



Observação: Caso tenha curiosidade de saber como esta árvore foi construída, veja o código “decision_tree_iris.ipynb” disponível no CANVAS.

Com base nestas informações, quais serão as saídas da árvore (classes preditas) para os seguintes registros de teste?

ID	Tamanho da Pétala (petallength)	Largura da Pétala (petalwidth)	Tamanho da Sépala (sepallength)	Largura da Sépala (sepalwidth)
1	3.46	0.87	2.45	1.78
2	1.67	1.89	0.78	1.32
3	2.56	2.34	0.78	1.78
4	6.67	2.34	2.45	1.78

R:

- 1: Iris-versicolor
 - 2: Iris-setosa
 - 3: Iris-virginica
 - 4: Iris-virginica
-

Questão 05. Considere a seguinte matriz de confusão obtida para o problema do restaurante (i.e., o objetivo era decidir se espero uma mesa em um restaurante) por meio de uma Árvore de Decisão:

		Classe Predita	
		SIM	NÃO
Classe Verdadeira	Vou esperar?		
	SIM	15	3
	NÃO	5	10

Quais são os valores das métricas abaixo para cada uma das classes (SIM/NÃO)?

R:

	TVP	TFN	TFP	TVN	Precisão	Recall	F1-Score
SIM	15/18	3/18	5/15	10/15	0,75	0,83	0,787
NÃO	10/15	5/15	3/18	15/18	0,77	0,67	0,716

Questão 06. Considere agora uma matriz de confusão obtida por meio de uma Árvore de Decisão para um problema genérico de classificação de quatro classes:

		Classe Predita			
		A	B	C	D
Classe Verdadeira	A	10	4	2	1
	B	1	15	2	0
	C	2	3	20	5
	D	4	1	2	50

Quais são os valores das métricas abaixo para cada uma das classes A, B, C e D?

R:

	TVP	TFN	TFP	TVN	Precisão	Recall	F1-Score
A	10/17	7/17	7/105	98/105	0,588	0,588	0,588
B	15/18	3/18	8/104	96/104	0,652	0,833	0,731
C	20/30	10/30	6/92	86/92	0,769	0,666	0,713
D	50/57	7/50	6/65	59/65	0,892	0,877	0,884