

Lista de Exercícios #2 – Árvores de Decisão

Aluno: Thiago Henrique Gomes Feliciano - 1543790

Questão 01. Sobre os conceitos de Árvores de Decisão, responda:

1. Como uma árvore de decisão é gerada? Qual o significado do atributo que está na raiz da árvore?

R:

- Começa com todo o conjunto de dados no nó inicial (raiz);
- O algoritmo testa cada atributo do conjunto de dados para descobrir qual deles separa melhor os exemplos em classes diferentes;
- O atributo que melhor separa os dados é escolhido para fazer a divisão;
- O conjunto de dados é então dividido em subconjuntos de acordo com os valores desse atributo;
- Para cada subconjunto, o processo é repetido recursivamente, criando novos nós.

Um atributo estar na raiz da árvore significa que ele é o atributo que melhor separa os dados no conjunto inteiro.

2. Qual a diferença entre os nós internos e os nós de folha de uma árvore de decisão?

R: Os nós internos testam um dos atributos de entrada, os nós de folhas são os valores que podem ser retornados.

3. O que você pode fazer com uma árvore de decisão gerada a partir de uma base de dados?

R: Pode se usar para classificação, previsão, extração de regras de decisão, ajudar a tomar decisões, análise e interpretação de dados.

4. Quais as principais vantagens e desvantagens de um algoritmo de árvore de decisão?

R: Suas principais vantagens são a sua flexibilidade, sua seleção de atributos(assim tirando atributos irrelevantes), interpretabilidade, eficiência. Suas principais desvantagens são sua não conseguir lidar com valores ausentes, tendo que usar mecanismos para empregar valores a eles, dificuldade de lidar com atributos contínuos, instabilidade(pequenas variações no conjunto de treinamento produzem grandes variações na árvore final).

5. Como avaliamos a qualidade de uma árvore?

R: Através do VP, VN, FP, FN, acurácia, precisão, sensibilidade (recall), F1-score.

6. Como podemos obter as regras a partir de uma árvore de decisão?

R: Para obter regras de uma árvore de decisão percorre-se cada caminho da raiz até uma folha, combinando as condições dos nós internos com “E”, a folha indica o resultado final da regra.

Questão 02. Considere o conjunto de dados sobre “Esperar ou não pelo restaurante” (verifique o arquivo “restaurante.csv” no CANVAS) e faça:

1. Calcule o ganho de informação para cada atributo. Qual será o atributo raiz da árvore?


R:

Alternativo: 0
Bar: 0
SexSab: 0,021
fome: 0,196
Cliente: 0,541
Preco: 0,196
Chuva: 0,02
Res: 0,021
Tipo: 0
Tempo: 0,21

O atributo raiz da árvore será “Cliente”, pois é o que traz mais informação.

2. Qual atributo estará no segundo nível da árvore? Faça os cálculos e apresente a árvore gerada até o segundo nível.

R: Será o atributo “Tempo”, pois depois do atributo “cliente” é o que mais dá ganho de informação.



Questão 03. Leia o artigo “A comparative study of decision tree ID3 and C4.5” que está no CANVAS e responda:

1. Quais as diferenças entre os algoritmos de árvore ID3 e C4.5?

2. Como o algoritmo C4.5 lida com os atributos de entrada que são numéricos?

Questão 04. A figura abaixo mostra uma árvore de decisão construída a partir de um conjunto de dados no qual as instâncias são descritas por quatro atributos: (i) Tamanho da Pétala, (ii) Largura da Pétala, (iii) Tamanho da Sépala e (iv) Largura da Sépala.

```

graph TD
    Root["petalength <= 2.45  
gini = 0.667  
samples = 150  
value = [50, 50, 50]  
class = Iris-setosa"]
    True["True"]
    False["False"]
    L1_0["gini = 0.0  
samples = 50  
value = [50, 0, 0]  
class = Iris-setosa"]
    L1_1["petalwidth <= 1.75  
gini = 0.5  
samples = 100  
value = [0, 50, 50]  
class = Iris-versicolor"]
    L2_0["petalength <= 4.95  
gini = 0.168  
samples = 54  
value = [0, 49, 5]  
class = Iris-versicolor"]
    L2_1["petalength <= 4.85  
gini = 0.043  
samples = 46  
value = [0, 1, 45]  
class = Iris-virginica"]
    L3_0["gini = 0.041  
samples = 48  
value = [0, 47, 1]  
class = Iris-versicolor"]
    L3_1["gini = 0.444  
samples = 6  
value = [0, 2, 4]  
class = Iris-virginica"]
    L3_2["gini = 0.444  
samples = 3  
value = [0, 1, 2]  
class = Iris-virginica"]
    L3_3["gini = 0.0  
samples = 43  
value = [0, 0, 43]  
class = Iris-virginica"]

    Root -- True --> L1_0
    Root -- False --> L1_1
    L1_1 -- True --> L2_0
    L1_1 -- False --> L2_1
    L2_0 -- True --> L3_0
    L2_0 -- False --> L3_1
    L2_1 -- True --> L3_2
    L2_1 -- False --> L3_3
  
```

petalength <= 2.45
gini = 0.667
samples = 150
value = [50, 50, 50]
class = Iris-setosa

True

False

gini = 0.0
samples = 50
value = [50, 0, 0]
class = Iris-setosa

petalwidth <= 1.75
gini = 0.5
samples = 100
value = [0, 50, 50]
class = Iris-versicolor

petalength <= 4.95
gini = 0.168
samples = 54
value = [0, 49, 5]
class = Iris-versicolor

petalength <= 4.85
gini = 0.043
samples = 46
value = [0, 1, 45]
class = Iris-virginica

gini = 0.041
samples = 48
value = [0, 47, 1]
class = Iris-versicolor

gini = 0.444
samples = 6
value = [0, 2, 4]
class = Iris-virginica

gini = 0.444
samples = 3
value = [0, 1, 2]
class = Iris-virginica

gini = 0.0
samples = 43
value = [0, 0, 43]
class = Iris-virginica

Com base nestas informações, quais serão as saídas da árvore (classes preditas) para os seguintes registros de teste?

ID	Tamanho da Pétala (<i>petallength</i>)	Largura da Pétala (<i>petalwidth</i>)	Tamanho da Sépala (<i>sepallength</i>)	Largura da Sépala (<i>sepalwidth</i>)
1	3.46	0.87	2.45	1.78
2	1.67	1.89	0.78	1.32
3	2.56	2.34	0.78	1.78
4	6.67	2.34	2.45	1.78

R:

- 1: Iris-versicolor
- 2: Iris-setosa
- 3: Iris-virginica
- 4: Iris-virginica

Questão 05. Considere a seguinte matriz de confusão obtida para o problema do restaurante (i.e., o objetivo era decidir se espero uma mesa em um restaurante) por meio de uma Árvore de Decisão:

		Classe Predita	
		SIM	NÃO
Classe Verdadeira	Vou esperar? SIM	15	3
	NÃO	5	10

Quais são os valores das métricas abaixo para cada uma das classes (SIM/NÃO)?

R:

	TVP	TFN	TFP	TVN	Precisão	Recall	F1-Score
SIM	15/18	3/18	5/15	10/15	0,75	0,83	0,787
NÃO	10/15	5/15	3/18	15/18	0,77	0,67	0,716

Questão 06. Considere agora uma matriz de confusão obtida por meio de uma Árvore de Decisão para um problema genérico de classificação de quatro classes:

		Classe Predita			
		A	B	C	D
Classe Verdadeira	A	10	4	2	1
	B	1	15	2	0
	C	2	3	20	5
	D	4	1	2	50

Quais são os valores das métricas abaixo para cada uma das classes A, B, C e D?

R:

	TVP	TFN	TFP	TVN	Precisão	Recall	F1-Score
A	10/17	7/17	7/105	98/105	0,588	0,588	0,588
B	15/18	3/18	8/104	96/104	0,652	0,833	0,731
C	20/30	10/30	6/92	86/92	0,769	0,666	0,713
D	50/57	7/50	6/65	59/65	0,892	0,877	0,884