

Lista de Exercícios #3 – Amostragem, Ensemble Learning e Naive Bayes

Aluno: Thiago Henrique Gomes Feliciano - 1543790

Questão 01. Sobre os conceitos de métodos de amostragem, responda:

1. Qual a importância de separar um conjunto de dados em conjuntos de treinamento e de teste?

R: Separar os dados permite avaliar se o modelo consegue generalizar para dados novos. O treinamento é usado para aprender padrões e o teste é usado para avaliar o desempenho em dados não vistos. Sem essa separação, o modelo pode apenas “decorar” os dados (overfitting), levando a uma avaliação enganosa.

2. Qual a principal limitação do método holdout em relação à partição dos dados e de que forma a Amostragem Aleatória busca mitigar esse problema?

R: O método holdout depende muito da forma que o conjunto de dados é particionado. Pode acontecer de exemplos “mais fáceis” caírem no subconjunto de teste.

3. Em um cenário de 5-fold cross-validation (validação cruzada), qual a porcentagem média de exemplos compartilhados entre os diferentes subconjuntos de treinamento?

R: 60%. Para descobrir a porcentagem se usa a fórmula: $(1 - 2/r)$; que é igual a $(1 - \frac{2}{5}) = 0,6$.

4. Qual a principal diferença entre os métodos de Amostragem Aleatória e Bootstrap?

R: A principal diferença é que a “Amostragem Aleatória” faz uma seleção sem reposição e o “Bootstrap” faz uma seleção com reposição.

5. Em métodos de aprendizado de máquina, qual a diferença entre as definições de “parâmetros” e “hiperparâmetros”? Cite exemplos no contexto de árvores de decisão.

R:

Parâmetros: aprendidos automaticamente pelo modelo durante o treinamento;

Hiperparâmetros: definidos antes do treinamento, controlam o comportamento do modelo;

Em árvores de decisão:

Parâmetro: estrutura da árvore (divisões, nós, folhas);

Hiperparâmetros: profundidade máxima da árvore, número mínimo de amostras por folha e critério de divisão;

6. Qual a importância de um conjunto de validação distinto do conjunto de teste final?

R: O conjunto de validação ajusta hiperparâmetros, escolhendo o melhor modelo. O conjunto de teste final deve ser usado apenas uma vez, para avaliação final.

Questão 02. Uma pessoa cientista de dados treinou um modelo de classificação utilizando resubstituição para avaliação e obteve acurácia de 100%. Entretanto, ao aplicar o modelo em novos dados, a acurácia caiu para 62%. Explique por que isso ocorreu e proponha uma estratégia de avaliação mais adequada.

R: Isso ocorreu por causa de um “overfitting”, quando o cientista de dados usou resubstituição, ela avaliou o modelo nos mesmos dados usados no treinamento. O modelo pode ter simplesmente decorado os dados, o que leva a essa acurácia artificial de 100%, ao aplicar em novos dados (não vistos), o modelo mostrou seu desempenho real (62%), mostrando que não generalizou bem.

Questão 03. Considere um modelo avaliado por 10-fold cross-validation. Se o conjunto de dados possui 200 exemplos, quantos exemplos são usados para teste em cada iteração?

R: Em cada iteração, 20 exemplos são usados para teste, enquanto os outros 180 exemplos são usados para treinamento. Pois a porcentagem usada para treinamento é de $r-1$, ou seja 90% é usada para treinamento e 10% para teste.

Questão 04. Sobre métodos de ensemble, responda:

1. Explique a razão pela qual métodos ensemble tendem a apresentar melhor desempenho do que classificadores individuais.

R: Os métodos de ensemble combinam vários modelos (classificadores) para tomar uma decisão final. O porquê do melhor desempenho é que eles reduzem erros individuais.

2. Quais os principais tipos de métodos ensemble e qual a principal diferença entre eles?

R: Os principais métodos são o “Bagging”, “Boosting” e “Stacking”. O Bagging cria múltiplos sub conjuntos de treino, ele treina um indutor de cada subconjunto e combina os resultados (geralmente por média ou votação). O Boosting treina modelos sequencialmente e cada novo modelo tenta corrigir os erros do anterior. O Stacking combina previsões de múltiplos modelos usando um meta-modelo.

3. Como o algoritmo Random Forest garante que as árvores criadas sejam diferentes entre si, além do uso de Bootstrap?

R: Além do Bootstrap, ele usa um subconjunto aleatório de atributos em cada divisão da árvore.

Questão 05. Em um ensemble baseado em bagging, dez classificadores retornaram as seguintes previsões:

Classificador	Previsão
C1	Positivo
C2	Positivo
C3	Negativo
C4	Positivo
C5	Negativo
C6	Negativo
C7	Positivo
C8	Negativo
C9	Negativo
C10	Negativo

Qual será a predição final? Justifique sua resposta.

R: A predição final será “Negativo”, pois em um ensemble baseado em bagging, a decisão final é feita por votação majoritária, como a classe “Negativo” recebeu 6 votos, e o “Positivo” recebeu 4 votos, o “Negativo” é a escolhida como predição final.

Questão 06. Sobre Naive Bayes, responda:

1. Por que o classificador Naive Bayes é chamado de “ingênuo”? Explique a suposição de independência e discuta se ela é realista em problemas do mundo real.

R: Ele é chamado de ingênuo porque ele assume a independência dos atributos. Na vida real os atributos nem sempre são independentes, mas o Naive Bayes costuma funcionar muito bem.

2. Como o Naive Bayes lida com atributos numéricos (contínuos) em comparação com atributos categóricos?

R: Atributos categóricos o modelo calcula probabilidades diretamente a partir de frequências. Atributos numéricos (contínuos) não dá para usar frequências diretamente, então o modelo assume que os dados seguem uma distribuição de probabilidade.

Questão 07. Uma loja de eletrônicos deseja prever se um cliente comprará um produto com base em sua idade, renda e se é estudante ou não. O histórico de clientes desta loja é dado pela tabela:

Cliente	Idade	Renda	Estudante	Compra
c1	Jovem	Alta	Não	Não
c2	Jovem	Alta	Não	Não
c3	Meia-idade	Alta	Não	Sim
c4	Idoso	Média	Não	Sim
c5	Idoso	Baixa	Sim	Sim
c6	Idoso	Baixa	Sim	Não
c7	Meia-idade	Baixa	Sim	Sim
c8	Jovem	Média	Não	Não
c9	Jovem	Baixa	Sim	Sim
c10	Idoso	Média	Sim	Sim

Dado um novo cliente que é jovem, tem renda média e é estudante, qual será a predição realizada por um classificador Naive Bayes? Mostre os cálculos das probabilidades e indique a classe final.

R:

	Idade			Renda			Estudante	
Compra	Jovem	Meia-Idade	Idoso	Baixa	Média	Alta	Sim	Não
SIM 6/10	1/6	2/6	3/6	3/6	2/6	1/6	4/6	2/6
NÃO 4/10	3/4	0/4	1/4	1/4	1/4	2/4	1/4	3/4

• LISTA 3%

⑦ • COMPRA:

$$P(\text{sim}) = \frac{6}{10} = 0,6$$

$$P(\text{não}) = \frac{4}{10} = 0,4$$

• P(sim):

- IDADE: $P(\text{JOVEM}/\text{sim}) = \frac{1}{6} = 0,167$
- RENDA: $P(\text{MÉDIA}/\text{sim}) = \frac{2}{6} = 0,333$
- ESTUDANTE: $P(\text{sim}/\text{sim}) = \frac{3}{6} = 0,5$

• P(NÃO):

- IDADE: $P(\text{JOVEM}/\text{não}) = \frac{3}{4} = 0,75$
- RENDA: $P(\text{MÉDIA}/\text{não}) = \frac{1}{4} = 0,25$
- ESTUDANTE: $P(\text{sim}/\text{não}) = \frac{1}{4} = 0,25$

• $P(\text{sim}/x) \propto P(\text{sim}) \cdot P(\text{JOVEM}/\text{sim}) \cdot P(\text{MÉDIA}/\text{sim}) \cdot P(\text{ESTUDANTE}/\text{sim}) =$

$$= \frac{6}{10} \cdot \frac{1}{6} \cdot \frac{2}{6} \cdot \frac{3}{6} = 0,6 \cdot \frac{8}{216} = 0,0222$$

• $P(\text{não}/x) \propto P(\text{não}) \cdot P(\text{JOVEM}/\text{não}) \cdot P(\text{MÉDIA}/\text{não}) \cdot P(\text{ESTUDANTE}/\text{não}) =$

$$= \frac{4}{10} \cdot \frac{3}{4} \cdot \frac{1}{4} \cdot \frac{1}{4} = 0,4 \cdot \frac{3}{64} = 0,4 \cdot 0,046875 = 0,01875$$

$P(\text{sim}/x) > P(\text{não}/x)$

$$0,0222 > 0,01875$$

• PREDIÇÃO: COMPRA = sim //

A predição será igual a SIM.