

Lista de Exercícios #4 – Associação e Pré-processamento de Dados

Aluno: Thiago Henrique Gomes Feliciano - 1543790

Questão 01. Considere que em um supermercado foram efetuadas as seguintes transações:

Transação	Itens
1	Detergente, Limão, Feijão
2	Álcool, Detergente, Limão
3	Álcool, Detergente, Arroz
4	Limão
5	Limão
6	Álcool, Limão, Arroz, Feijão
7	Álcool, Detergente, Limão

Utilizando o algoritmo Apriori com um suporte mínimo de 0.3 e confiança mínima de 0.6, gere:

1. Os conjuntos de itens (itemsets) frequentes, com seus respectivos suportes

R:

Handwritten calculations for frequent itemsets using the Apriori algorithm. The calculations are organized into three sections: 1-ITEMS, 2-ITEMSETS, and 3-ITEMSETS. Each section lists itemsets and their support values, with checkmarks for those meeting the minimum support of 0.3.

LISTA 4	
①	
1. ITEMS	SUPORTE
detergente	$\frac{4}{7} = 0,57 \checkmark$
limão	$\frac{6}{7} = 0,86 \checkmark$
Feijão	$\frac{2}{7} = 0,28 \times$
Álcool	$\frac{4}{7} = 0,57 \checkmark$
Arroz	$\frac{2}{7} = 0,28 \times$
2-ITEMSETS :	
{detergente, limão}	$\rightarrow \frac{3}{7} = 0,43 \checkmark$
{detergente, Álcool}	$\rightarrow \frac{3}{7} = 0,43 \checkmark$
{Álcool, limão}	$\rightarrow \frac{3}{7} = 0,43 \checkmark$
3-ITEMSETS :	
{detergente, limão, álcool}	$\rightarrow \frac{2}{7} = 0,28 \times$

2. As regras de associação derivadas, com os respectivos valores de confiança e lift

R:

2. • {detergente, limão} :

→ detergente → limão = ✓

$$\text{confiança}(D \rightarrow L) = \frac{3}{4} = 0,75 \checkmark$$

$$\text{lift}(D \rightarrow L) = \frac{0,75}{\frac{6}{7}} = 0,875 \checkmark$$

→ limão → detergente = ✗

$$\text{confiança}(L \rightarrow D) = \frac{3}{6} = 0,5 \text{ ✗}$$

$$\text{lift}(L \rightarrow D) = \frac{0,5}{0,57} = 0,877$$

• { Detergente, álcool } : ✓
 → Detergente → álcool : ✓

$$\text{confiança } (D \rightarrow A) = \frac{3}{4} = 0,75$$

$$\text{lift } (D \rightarrow A) = \frac{0,75}{0,57} = 1,32 //$$

→ Álcool → Detergente : ✓

$$\text{confiança } (A \rightarrow D) = \frac{3}{4} = 0,75$$

$$\text{lift } (A \rightarrow D) = \frac{0,75}{0,57} = 1,32 //$$

• { Álcool, limão } :
 → Álcool → limão : ✓

$$\text{confiança } (A \rightarrow L) = \frac{3}{4} = 0,75$$

$$\text{lift } (A \rightarrow L) = \frac{0,75}{0,86} = 0,87$$

→ Limão → Álcool : ✗

$$\text{confiança } (L \rightarrow A) = \frac{3}{6} = 0,5$$

$$\text{lift } (L \rightarrow A) = \frac{0,5}{0,57} = 0,88 //$$

• REGRAS :

Detergente → limão
 Detergente → álcool
 Álcool → detergente
 Álcool → limão

Questão 02. Sobre técnicas de pré-processamento de dados, responda:

1. Quando falamos de balanceamento de dados, qual a diferença entre as técnicas de oversampling e undersampling?

R: No oversampling se adiciona instâncias à classe minoritária(risco de as instâncias acrescentadas representarem situações em nunca ocorrerão e de overfitting). No undersampling se remove instâncias da classe majoritária(é possível que dados de grande importância sejam perdidos e que ocorra underfitting).

2. Para o tratamento de dados ausentes, qual a estratégia mais recomendada quando não podemos/quero remover instâncias e atributos do conjunto de dados?

R: Utilizar algum método ou heurística para automaticamente definir valores para atributos com valores ausentes, podendo ser através da moda, média ou mediana dos valores dos atributos.

3. Qual a principal forma de se verificar se um atributo é redundante sem saber se ele foi gerado a partir de outro atributo?

R: A principal forma é analisar a correlação entre atributos, caso tenha existe uma possível redundância.

4. O que é a binarização de um atributo e quando não é uma boa opção utilizá-la?

R: A codificação 1-de-c (one-hot encoding) ou binarização é uma técnica usada para representar atributos categóricos em formato numérico. Nela, cada categoria possível é transformada em um vetor binário, no qual apenas uma posição assume o valor 1 (indicando a categoria presente) e todas as outras posições são 0. Não é muito bom usá-lo quando se tem muitas categorias, quando existe ordem natural entre os valores.

5. O que é a discretização de um atributo e quais as principais estratégias para realizá-la?

R: É transformar um atributo numérico contínuo em categorias/faixa, as principais estratégias são intervalos de mesma largura e intervalos de mesma frequência.

6. Qual a diferença entre as normalizações por reescala (MinMax) e por padronização (Z-score)?

R: MinMax (reescala): transforma os dados para um intervalo fixo (geralmente 0 a 1).
Z-score (padronização): transforma os dados para média 0 e desvio padrão 1.