

Lista de Exercícios #7 – Redes Neurais Convolucionais e Técnicas de Agrupamento

Aluno: Thiago Henrique Gomes Feliciano - 1543790

Questão 01. Sobre os principais conceitos de redes neurais convolucionais (CNNs), responda:

1. Cite e explique os principais problemas de se usar uma rede MLP (totalmente conectada) para classificar imagens.

R: Os principais problemas de usar uma MLP para classificar imagens são eles, muitos parâmetros: cada pixel é conectado a todos os neurônios da próxima camada, gerando milhões de pesos para aprender. Alto custo computacional: exige muita memória e processamento. Ignora a estrutura espacial da imagem: não considera que pixels vizinhos estão relacionados. Maior risco de overfitting: devido ao grande número de parâmetros. Pouco eficiente para detectar padrões locais: como bordas, texturas e formas.

2. Descreva, na ordem correta, as quatro etapas principais da arquitetura de uma CNN e diga qual é a função de cada uma.

R:

1. Convolução: Tem como função extrair características da imagem. A rede passa pequenos filtros matemáticos (kernels) por toda a imagem, cada filtro procura um padrão específico: linhas retas e bordas, depois formas geométricas e nas camadas mais profundas, partes complexas como focinhos ou olhos. O resultado é um mapa de características (feature map) que destaca as informações importantes da imagem, Ex: detectar olhos.

2. Pooling: Tem como função reduzir a dimensionalidade dos dados (Seleciona as características mais relevantes da imagem). Recebe o feature map gerado pela convolução, mantém apenas as informações mais relevantes, o método mais comum é o Max Pooling, que seleciona o maior valor de cada região analisada, diminui o custo computacional e ajuda a evitar o overfitting. Ex: Em vez de guardar a posição exata de uma borda, a rede guarda apenas a informação de que ela existe naquela região.

3. Flattening: Tem como função transformar as matrizes em um vetor. Após as etapas de convolução e pooling, os dados ainda estão organizados em matrizes, o flattening converte essas matrizes em um único vetor unidimensional, esse vetor pode ser utilizado pela etapa de classificação

4. Rede Neural Densa: Tem como função realizar a classificação final. Recebe o vetor produzido pelo Flattening, combina todas as características extraídas anteriormente, calcula a probabilidade de cada classe e produz a resposta final. Ex: após analisar características como orelhas, olhos e pelos, a rede conclui: Gato: 95% e Cachorro: 5%.

3. O que é um kernel (filtro) na etapa de convolução e o que é o feature map (mapa de características)? Por que diferentes kernels produzem resultados diferentes?

R: O kernel (filtro) é uma pequena matriz de números que percorre a imagem durante a etapa de convolução. Sua função é procurar padrões específicos na imagem, como bordas,

linhas, texturas ou formas. O feature map é a matriz resultante da aplicação de um kernel sobre toda a imagem. Ele indica onde o padrão procurado pelo filtro foi encontrado.

4. Explique a diferença entre max pooling e average pooling. Considere a seguinte região 2×2 de um feature map e calcule o resultado para cada tipo de pooling:

29	15
0	100

R: Max Pooling: Seleciona o maior valor da região analisada. Destaca a característica mais forte encontrada e é o método mais utilizado em CNNs.

max_pooling: $\max(29, 15, 0, 100) = 100$.

Average Pooling: Calcula a média dos valores da região analisada. Preserva uma visão mais geral da informação e pode suavizar detalhes importantes.

average_pooling: $(29+15+0+100)/4 = 144/4 = 36$.

5. Qual é a função da etapa de flattening dentro da CNN? Por que ela é necessária antes da rede densa?

R: O Flattening é a terceira etapa principal de uma CNN, sua função é transformar os mapas de características (matrizes) em um vetor unidimensional. As camadas de convolução e pooling produzem saídas no formato de matrizes, porém, a etapa final de classificação geralmente é feita por uma rede neural densa (MLP), que recebe seus dados na forma de um vetor de entrada.

Questão 02. Em relação às técnicas de agrupamento vistas em sala, responda:

1. O objetivo do agrupamento é organizar os dados em grupos. Descreva, com suas palavras, as duas propriedades que um bom agrupamento deve satisfazer em relação à similaridade dos objetos (dentro e entre grupos).

R: Alta similaridade dentro do grupo (coesão): os objetos que pertencem ao mesmo cluster devem ser muito parecidos entre si, compartilhando características semelhantes.

Baixa similaridade entre grupos (separação): os objetos de clusters diferentes devem ser o mais diferentes possível, formando grupos bem distintos uns dos outros.

2. Um mesmo conjunto de objetos pode ser agrupado de maneiras diferentes dependendo do critério escolhido (lembre-se do exemplo dos animais: "com bico / sem bico", "água / terra", etc.). O que isso revela sobre a natureza do problema de agrupamento? Existe uma única resposta "correta"? Por quê?

R: Isso revela que o agrupamento é um problema subjetivo e dependente do objetivo da análise. Um mesmo conjunto de dados pode ser agrupado de diferentes formas válidas,

dependendo das características consideradas mais importantes. Não existe uma única resposta correta para o agrupamento, porque não há rótulos previamente definidos indicando como os objetos devem ser organizados. Diferentes critérios de similaridade podem produzir agrupamentos diferentes, e todos podem ser adequados para finalidades distintas.

3. Cite pelo menos três limitações do algoritmo K-Means e, para cada uma delas, indique uma estratégia ou técnica para contorná-la.

R: *Precisa definir k manualmente:* Não sabe quantos grupos existem. Solução: utilizar o Método do Cotovelo (Elbow Method) para ajudar na escolha do valor de k.

Sensível aos centroides iniciais: Centroides iniciais aleatórios podem gerar resultados completamente diferentes a cada execução. Solução: utilizar o K-Means++, que escolhe centroides iniciais mais bem distribuídos.

Assume grupos esféricos: Não funciona bem com clusters de formato irregular. Solução: utilizar algoritmos baseados em densidade, como o DBSCAN, que encontra clusters de formatos variados.

Sensível a diferentes tamanhos/densidades: Grupos muito maiores ou mais densos “dominam” os menores. Solução: usar mais grupos inicialmente e depois unir clusters próximos, ou optar por algoritmos mais adequados para densidades diferentes.

4. O Sum of Squared Error (SSE) é uma métrica de qualidade de agrupamento. Explique o que ele mede e por que não faz sentido escolher o número de grupos k simplesmente buscando o menor SSE possível. Como o Método do Cotovelo (Elbow Method) ajuda nessa decisão?

R: O SSE (Sum of Squared Error) mede o quão compactos são os clusters, calculando a soma das distâncias quadradas de cada ponto ao centroide do seu grupo. Quanto menor o SSE, mais próximos os pontos estão do centroide e mais compacto é o cluster. Porém, não faz sentido escolher k apenas pelo menor SSE, porque o SSE sempre diminui quando aumentamos o número de clusters. No limite, se cada ponto formar seu próprio cluster, o SSE será igual a zero, mas isso não representa um agrupamento útil. Assim, o Método do Cotovelo ajuda a encontrar um valor de k que equilibra qualidade do agrupamento e simplicidade do modelo.

5. O Silhouette Index de um ponto pode variar entre -1 e 1. Interprete o significado de um valor próximo de 1, próximo de 0 e próximo de -1. Como obtemos um índice único para avaliar o agrupamento como um todo?

R: O Silhouette Index mede o quão bem um ponto está associado ao seu próprio cluster em comparação com os clusters vizinhos. Seus valores variam entre -1 e 1.

- Valor próximo de 1: o ponto está bem agrupado, sendo muito semelhante aos elementos do seu próprio cluster e bem distante dos outros clusters.

- Valor próximo de 0: o ponto está próximo da fronteira entre dois clusters, podendo pertencer a qualquer um deles.

- Valor próximo de -1: o ponto está mais próximo de outro cluster do que do cluster ao qual foi atribuído, indicando possível classificação incorreta.

Primeiro calcula-se o valor de Silhouette para cada ponto do conjunto de dados. Em seguida, obtém-se o Silhouette Index Global, que é a média dos valores de Silhouette de todos os pontos. Esse valor único permite avaliar a qualidade geral do agrupamento e comparar diferentes soluções. Ex: diferentes valores de k no K-Means.

Questão 03. Uma plataforma de streaming coletou as avaliações (notas de 1 a 5) que seis usuários deram a quatro filmes. O objetivo é agrupar os usuários em dois grupos de gosto semelhante, e as avaliações de cada usuário, na ordem (Filme 1, Filme 2, Filme 3, Filme 4), são:

- Usuário 1: (5, 3, 1, 1)
- Usuário 2: (3, 1, 5, 3)
- Usuário 3: (2, 1, 5, 3)
- Usuário 4: (4, 3, 4, 2)
- Usuário 5: (5, 5, 3, 1)
- Usuário 6: (3, 1, 5, 3)

Faça este agrupamento usando o algoritmo K-Means com distância euclidiana. Mostre o passo a passo das duas primeiras iterações do algoritmo. Considere como centroides iniciais:

- Centroide 1 (C1): (5, 3, 1, 1)
- Centroide 2 (C2): (3, 1, 5, 3)

R:

LISTA 7:

③ INTERAÇÃO 1:

• $U_1 = (5, 3, 1, 1)$:

$$d(U_1, C_1) = \sqrt{(5-5)^2 + (3-3)^2 + (1-1)^2 + (1-1)^2} = \sqrt{0} = 0 //$$

$$d(U_1, C_2) = \sqrt{(5-3)^2 + (3-1)^2 + (1-5)^2 + (1-3)^2} = \sqrt{4+4+16+4} = \sqrt{28} = 5,29$$

↪ Grupo 1

• $U_2 = (3, 1, 5, 3)$:

$$d(U_2, C_1) = \sqrt{28} = 5,29 \quad \rightarrow \text{grupo 2}$$

$$d(U_2, C_2) = 0$$

• $U_3 = (2, 1, 5, 3)$:

$$d(U_3, C_1) = \sqrt{9+4+16+4} = \sqrt{33} = 5,74$$

$$d(U_3, C_2) = \sqrt{1+0+0+0} = \sqrt{1} = 1$$

↪ grupo 2

• $U_4 = (4, 3, 4, 2)$:

$$d(U_4, C_1) = \sqrt{1+0+9+1} = \sqrt{11} = 3,32$$

$$d(U_4, C_2) = \sqrt{1+4+1+1} = \sqrt{7} = 2,65$$

↪ grupo 2

• $U_5 = (5, 5, 3, 1)$:

$$d(U_5, C_1) = \sqrt{0+4+4+0} = \sqrt{8} = 2,83$$

$$d(U_5, C_2) = \sqrt{4+16+4+4} = \sqrt{28} = 5,29$$

↪ grupo 1

• $U_6 = (3, 1, 5, 3)$:

$$d(U_6, C_1) = \sqrt{4+4+16+4} = \sqrt{28} = 5,29$$

$$d(U_6, C_2) = \sqrt{0+0+0+0} = \sqrt{0} = 0$$

↪ grupo 2

↳ RESULTADO:

• Cluster 1: U_1, U_5

• Cluster 2: U_2, U_3, U_4, U_6

• RECALCULAR CENTROIDES:

↳ NOVO C1:

$$C_1 = \left(\frac{5+5}{2}, \frac{5+3}{2}, \frac{1+3}{2}, \frac{1+1}{2} \right) = (5, 4, 2, 1)$$

$$C_1 = (5; 4; 2; 1)$$

↳ NOVO C2:

$$C_2 = \left(\frac{3+2+4+3}{4}, \frac{1+1+3+1}{4}, \frac{5+5+4+5}{4}, \frac{3+3+2+3}{4} \right)$$

$$C_2 = (3; 1,5; 4,75; 2,75)$$

• INTERAÇÃO 2:

$$U_1 = (5, 3, 1, 1):$$

$$d(U_1, C_1) = \sqrt{0+1+1+0} = \sqrt{2} = 1,41$$

$$d(U_1, C_2) = \sqrt{4+2,25+14,0625+3,0625} = \sqrt{23,375} = 4,83$$

↳ grupo 1.

$$U_2 = (3, 1, 5, 3):$$

$$d(U_2, C_1) = \sqrt{4+9+9+4} = \sqrt{26} = 5,10$$

$$d(U_2, C_2) = \sqrt{0+0,25+0,0625+0,0625} = \sqrt{0,375} = 0,61$$

↳ grupo 2

$$U_3 = (2, 1, 5, 3):$$

$$d(U_3, C_1) = \sqrt{9+9+9+4} = \sqrt{31} = 5,57$$

$$d(U_3, C_2) = \sqrt{1+0,25+0,0625+0,0625} = \sqrt{1,375} = 1,17$$

↳ grupo 2

$$U_4 = (4, 3, 4, 2):$$

$$d(U_4, C_1) = \sqrt{1+1+4+1} = \sqrt{7} = 2,65$$

$$d(U_4, C_2) = \sqrt{1+2,25+0,5625+0,5625} = \sqrt{4,375} = 2,09$$

↳ grupo 2.

$$U_5 = (5, 5, 3, 1)$$

$$d(U_5, C_1) = \sqrt{0+1+1+0} = \sqrt{2} = 1,41$$

$$d(U_5, C_2) = \sqrt{4+12,25+3,0625+3,0625} = \sqrt{22,375} = 4,73$$

↪ grupo 1

$$U_6 = (3, 1, 5, 3)$$

$$d(U_6, C_1) = \sqrt{4+9+9+4} = \sqrt{26} = 5,10$$

$$d(U_6, C_2) = \sqrt{0+0,25+0,0625+0,0625} = \sqrt{0,375} = 0,61$$

↪ grupo 2

↪ RESULTADOS:

CLUSTER 1: U_4, U_5

CLUSTER 2: U_2, U_3, U_4, U_6