

PONTIFÍCIA UNIVERSIDADE CATÓLICA DE MINAS GERAIS

Instituto de Ciências Exatas e Informática

Disciplina: Inteligência Artificial

Prof. Gabriel Pereira de Oliveira

Lista de Exercícios EXTRA – Pré-processamento e Agrupamento

Valor: 3 pontos

Esta lista de exercícios é baseada nos assuntos discutidos em aula e no conteúdo dos seguintes slides disponibilizados no CANVAS:

- 11 - Pré-processamento (Partes 1 a 7)
- 19 - Técnicas de Agrupamento

Orientações gerais:

- A entrega deverá ser feita em **um arquivo Jupyter Notebook (.ipynb)** desenvolvido em Python, contendo as respostas de ambas as questões. O notebook deve incluir os códigos utilizados, bem como células em Markdown com explicações claras sobre os procedimentos realizados, as análises desenvolvidas e os resultados obtidos.
- Fixe a mesma semente aleatória em todo o notebook para garantir a reprodutibilidade dos resultados.
- Para mais informações sobre Jupyter Notebooks, consulte:
 - [Introdução a Jupyter Notebooks](#)
 - [Capítulo de Livro sobre Ciência de Dados Usando Jupyter](#)

Objetivo. Trabalhar com o conjunto de dados [Credit Card Fraud Detection](#), que contém 284.807 transações de cartões de crédito realizadas por clientes europeus em dois dias de setembro de 2013, sendo 492 fraudes (0,172%), o que caracteriza um forte desbalanceamento entre as classes. As variáveis V1 a V28 são componentes obtidos por meio da PCA para preservar a confidencialidade dos dados originais, enquanto *Time* representa o tempo em segundos desde a primeira transação e *Amount* o valor da transação. A variável *Class* indica se uma operação é fraudulenta (1) ou não (0).

Questão 01. Construa um *pipeline de classificação* para detecção de fraude. Use um modelo à sua escolha dentre os vistos na disciplina (justifique a escolha) e mantenha o mesmo modelo e a mesma semente aleatória em todas as comparações. Execute as etapas abaixo:

1. **Análise exploratória:** visualização do conjunto, tipos de dados, distribuição das variáveis e proporção das classes.
2. **Valores ausentes:** verificação e, se houver, tratamento (descreva o método).

3. **Redundância e inconsistência:** detecção e remoção de registros duplicados ou inconsistentes.
4. **Análise de correlação e multicolinearidade:** examine as correlações. Comente o efeito esperado de V1–V28 serem componentes de PCA (logo, aproximadamente descorrelacionados).
5. **Divisão treino–teste estratificada:** separe os dados (ex.: 70/30 ou 80/20) preservando a proporção de classes. Todas as etapas seguintes que aprendem parâmetros devem ser ajustadas apenas no conjunto de treino.
6. **Outliers:** analise a presença de outliers. Discuta se, em detecção de fraude, outliers podem coincidir com a própria classe minoritária. Em outras palavras, justifique se devem ou não ser removidos.
7. **Normalização/padronização:** padronize os atributos. Ajuste o *scaler* no treino e aplique-o no teste.
8. **Codificação de variáveis:** verifique se há variáveis categóricas. Caso não haja, explique por que esta etapa não se aplica.
9. **Balanceamento de classe:** aplicado somente ao conjunto de treino. O conjunto de teste deve permanecer com a distribuição original, para simular um cenário de dados reais.

Avaliação da performance: treine e avalie o modelo. Como a base é desbalanceada, não use apenas acurácia como métrica principal. Reporte também *recall*, *precision*, F1 da classe minoritária, além da matriz de confusão.

Questão 02. Aplique os algoritmos K-Means e DBSCAN sobre os dados sem o atributo *Class* (o rótulo não é utilizado em agrupamentos) e compare os resultados.

- Para reduzir o custo computacional do agrupamento, utilize uma amostra de 10% do conjunto de treino.
- Utilize os atributos padronizados na questão anterior.
- **K-Means:** encontre o melhor valor de *k* (ex.: método do cotovelo variando *k* entre 2 e 5) e reporte os resultados.
- **DBSCAN:** utilize os valores padrão de *eps* e *min_samples*. Note que o número de clusters é descoberto pelo algoritmo (não imposto) e reporte quantos grupos e quantos *outliers* foram encontrados.

Avaliação da qualidade: reporte métricas vistas em aula, como coeficiente de silhueta e soma dos erros quadráticos (SSE).

Quaisquer dúvidas ou comentários, envie uma mensagem via CANVAS ou escreva um e-mail para gabrielpdoliveira@gmail.com.