

Nome: _____ Data: 22/04/2026

Instruções:

- Esta avaliação vale **30 pontos**.
- A avaliação é **individual** e **sem consulta**.
- A duração da avaliação é de **100 minutos**.
- Leia atentamente cada questão e assinale apenas uma alternativa por questão.
- Questões com cálculo devem apresentar o desenvolvimento (mesmo sendo objetivas).
- A interpretação faz parte da avaliação.

Formulário:

$$H(S) = - \sum_{i=1}^c p_i \log_2(p_i) \quad H(S, A) = \sum_{v \in \text{Valores}(A)} \frac{|S_v|}{|S|} H(S_v) \quad GI(S, A) = H(S) - H(S, A)$$
$$P(c|x_1, \dots, x_n) \propto P(c) \prod_{j=1}^n P(x_j|c) \quad \text{conf}(A \rightarrow B) = \frac{\text{sup}(A \cup B)}{\text{sup}(A)}$$

Questão 01 (1,5 ponto)

A escolha do algoritmo de Inteligência Artificial depende fundamentalmente da natureza da tarefa e da disponibilidade de rótulos. Sobre as tarefas de aprendizado, avalie:

- Classificação e Regressão são tarefas do paradigma não supervisionado, diferenciando-se pelo tipo de atributo alvo (categórico/numérico). **FALSA (são tarefas do paradigma supervisionado)**
- O Agrupamento (*clustering*) busca identificar perfis de similaridade, exigindo a definição prévia de um atributo de saída para guiar a formação dos grupos. **FALSA (não tem atributo de saída)**
- A tarefa de Associação foca em encontrar regras de dependência entre atributos categóricos, como padrões de compra em transações. **VERDADEIRA**

São CORRETAS as afirmações:

- Apenas III.**
- Apenas I e II.
- Apenas I e III.
- Apenas II e III.
- I, II e III.

Questão 02 (1,5 ponto)

Uma pessoa cientista de dados observa que seu modelo de Árvore de Decisão apresenta uma acurácia de 99% no conjunto de treinamento, mas apenas 62% no conjunto de teste. Sobre esse cenário, avalie as afirmações:

- I. O modelo está sofrendo de sobreajuste (*overfitting*), tendo memorizado ruídos dos dados de treino em vez de aprender padrões generalizáveis. **VERDADEIRA**
- II. Diminuir a complexidade do modelo (por exemplo, limitar a profundidade da árvore) ajudará a reduzir o erro no conjunto de teste. **VERDADEIRA**
- III. O modelo está sofrendo de subajuste (*underfitting*), que ocorre quando há poucos dados de treinamento. **FALSA (é o oposto, o modelo está sofrendo de *overfitting*)**

São CORRETAS as afirmações:

- a) Apenas I.
- b) Apenas I e II.**
- c) Apenas I e III.
- d) Apenas II e III.
- e) I, II e III.

Questão 03 (1,5 ponto)

A avaliação de modelos exige rigor estatístico para evitar estimativas tendenciosas (enviesadas). Avalie as seguintes afirmações sobre amostragem:

- I. O método *holdout* divide os dados em subconjuntos distintos, permitindo que o modelo utilize uma pequena amostra dos dados de teste durante o treinamento para otimização contínua. **FALSA (o modelo não vê os dados de teste)**
- II. A validação cruzada (*cross-validation*) é preferível ao *holdout* em conjuntos de dados pequenos, pois permite que todos os exemplos sejam usados tanto para treino quanto para teste em diferentes rodadas. **VERDADEIRA**
- III. Na validação cruzada estratificada, as proporções das classes no conjunto original são preservadas em cada partição. **VERDADEIRA**

São CORRETAS as afirmações:

- a) Apenas I.
- b) Apenas I e III.
- c) Apenas II e III.**
- d) I, II e III.
- e) Nenhuma afirmação está correta.

Questão 04 (1,5 ponto)

Os algoritmos indutores de árvores de decisão utilizam métricas para escolher a melhor forma de divisão. Sobre o funcionamento destes algoritmos, avalie:

- I. O algoritmo ID3 utiliza o Ganho de Informação baseado no índice Gini, mas esta métrica possui viés para atributos com muitos valores distintos. **FALSA (é baseada na Entropia)**
- II. O algoritmo C4.5 introduziu a Razão de Ganho (*Gain Ratio*) para corrigir o viés do ID3, penalizando atributos excessivamente fragmentados. **VERDADEIRA**


- III. O índice Gini, utilizado pelo algoritmo CART, mede a impureza de um nó, onde um valor zero indica um nó perfeitamente puro. **VERDADEIRA**

São CORRETAS as afirmações:

- a) Apenas I.
- b) Apenas II.
- c) Apenas I e II.
- d) **Apenas II e III.**
- e) I, II e III.

Questão 05 (1,5 ponto)

A partir da base *Iris* (cujos atributos são *sepal length*, *sepal width*, *petal length*, *petal width*; e as classes são: *Iris-setosa*, *Iris-versicolor*, *Iris-virginica*), treinou-se a árvore de decisão mostrada na figura abaixo (gerada com *DecisionTreeClassifier*, profundidade máxima = 3).



Sobre esta árvore de decisão, analise as afirmações:

- I. A profundidade máxima de três níveis não foi suficiente para separar perfeitamente as classes nos nós folha. **VERDADEIRA** (existem folhas com gini > 0, que indica que as classes não foram 100% separadas)
- II. O modelo apresenta *overfitting*, pois todas as folhas são puras. **FALSA** (mesmo motivo da anterior)
- III. Uma instância de teste com petal width = 0.5; petal length = 5.2; sepal width = 1.0 e sepal length = 2.1 deve ser classificada como **Iris-setosa**. **VERDADEIRA**

São CORRETAS as afirmações:

- a) Apenas I.
- b) Apenas II.
- c) Apenas III.

- d) Apenas I e III.
- e) I, II e III.

Questão 06 (1,5 ponto)

O classificador Naive Bayes é amplamente utilizado por sua simplicidade e eficiência computacional. Sobre este classificador, analise as afirmações abaixo:

- I. Ele é chamado de “ingênuo” (*naive*) porque assume que todos os atributos de entrada possuem forte dependência linear entre si, dada a classe. **FALSA (o NB assume que os atributos são independentes entre si)**
- II. Uma das abordagens utilizadas pelo Naive Bayes para lidar com atributos numéricos é a discretização. **VERDADEIRA**
- III. O Naive Bayes é especialmente eficiente para lidar com grandes volumes de dados e conjuntos de dados com muitos atributos, como na filtragem de spam. **VERDADEIRA**

São CORRETAS as afirmações:

- a) Apenas I.
- b) Apenas I e II.
- c) Apenas I e III.
- d) **Apenas II e III.**
- e) I, II e III.

Questão 07 (1,5 ponto)

Dados brutos frequentemente exigem tratamento antes de serem alimentados em modelos de aprendizado. Sobre as técnicas de pré-processamento de dados, avalie:

- I. A normalização por padronização (z-score) é útil quando os atributos possuem escalas muito diferentes, definindo novos limites mínimo e máximo para todos os atributos. **FALSA (isso é a normalização min-max)**
- II. Métodos de *undersampling* resolvem o desbalanceamento de classes aumentando o número de instâncias da classe minoritária. **FALSA (diminuem o número de instâncias da classe majoritária)**
- III. A codificação 1-de-c (ou binarização) transforma uma variável categórica nominal em múltiplos pseudoatributos binários, evitando a criação de ordens artificiais inexistentes. **VERDADEIRA**

São CORRETAS as afirmações:

- a) Apenas I.
- b) **Apenas III.**
- c) Apenas I e II.
- d) Apenas I e III.
- e) I, II e III.

Questão 08 (1,5 ponto)

Métodos de Ensemble combinam múltiplos classificadores para melhorar o desempenho final. Sobre estes métodos, avalie:

- I. O *Bagging* (e.g., Random Forest) utiliza amostragem Bootstrap para treinar modelos de forma paralela e independente, focando na redução da variância. VERDADEIRA
- II. O *Boosting* (e.g., XGBoost) treina modelos de forma sequencial, onde cada novo modelo busca corrigir os erros cometidos pelos anteriores, focando na redução do viés. VERDADEIRA
- III. O *Stacking* combina as saídas de diversos modelos base por votação (classe majoritária). FALSA (utiliza um meta-modelo)

São CORRETAS as afirmações:

- a) Apenas I.
- b) Apenas II.
- c) Apenas I e II.
- d) Apenas II e III.
- e) I, II e III.

Questão 09 (1,5 ponto)

Sobre as métricas de avaliação de algoritmos de aprendizado de máquina, avalie as seguintes afirmações:

- I. As dimensões de uma matriz de confusão correspondem às classes preditas e verdadeiras de um problema de classificação. VERDADEIRA
- II. O F1-score tende a privilegiar o recall (sensibilidade) em detrimento da precisão. FALSA (é uma média harmônica de ambas)
- III. Matrizes de confusão são utilizadas apenas para problemas de classificação binária, i.e., quando há apenas duas classes. FALSA (podem ser utilizadas para classificação de n classes)

São CORRETAS as afirmações:

- a) Apenas I.
- b) Apenas II.
- c) Apenas I e II.
- d) Apenas II e III.
- e) I, II e III.

Questão 10 (1,5 ponto)

Sobre as técnicas de redução de dimensionalidade e tratamento de atributos, avalie as seguintes afirmações:

- I. Atributos redundantes podem ser identificados por meio de análise de correlação. VERDADEIRA
- II. Uma das desvantagens da seleção de atributos por filtro é que tal abordagem é diretamente dependente do algoritmo de aprendizado que será utilizado posteriormente. FALSA (é independente do algoritmo)
- III. Codificar um atributo "Nível Profissional" (Júnior, Pleno, Sênior) como (1, 2, 3) é correto por se tratar de um atributo ordinal. VERDADEIRA

São CORRETAS as afirmações:

- a) Apenas I.
- b) Apenas III.
- c) Apenas I e II.
- d) Apenas I e III.
- e) I, II e III.

Questão 11 (1,5 ponto)

No contexto de regras de associação, suponha que em um conjunto de dados de uma lanchonete, tenha sido encontrada a regra de associação **{Pão, Manteiga} → {Café}** com confiança de 0.8. Sobre esta regra, avalie as seguintes afirmações:

- I. O suporte avalia a proporção de transações que contêm os itens {Pão, Manteiga, Café}. **VERDADEIRA**
- II. Esta regra diz que, em 80% das vezes em que alguém compra Pão e Manteiga, a pessoa também adquire café. **VERDADEIRA**
- III. Um lift maior do que 1 para esta regra indica que {Café} é mais provável de ser comprado independentemente de {Pão, Manteiga}. **FALSA (significa o oposto: que é mais provável de ser comprado junto com {Pão, Manteiga})**

São CORRETAS as afirmações:

- a) Apenas I.
- b) Apenas III.
- c) Apenas I e II.
- d) Apenas I e III.
- e) I, II e III.

Questão 12 (1,5 ponto)

Sobre o algoritmo Apriori e a geração de regras de associação, avalie as afirmações:

- I. A primeira fase do algoritmo corresponde à identificação dos conjuntos de itens frequentes, que devem conter um valor mínimo de confiança. **FALSA (deve conter um valor mínimo de suporte)**
- II. O mecanismo de poda do Apriori utiliza uma propriedade que diz que se um conjunto de itens é pouco frequente, todos os seus superconjuntos também devem ser pouco frequentes. **VERDADEIRA**
- III. O Apriori gera regras de associação exclusivamente a partir dos conjuntos de itens frequentes previamente extraídos na primeira etapa. **VERDADEIRA**

São CORRETAS as afirmações:

- a) Apenas I.
- b) Apenas II.
- c) Apenas III.
- d) Apenas II e III.
- e) I, II e III.

Questão 13 (4 pontos)

Considere o processo de indução de uma árvore de decisão utilizando o algoritmo ID3 sobre o dataset de referência abaixo, sobre o risco de *churn* (cancelamento de serviço/app).

Atributos de entrada: Uso do App (Baixo/Alto), Pagamento (Boleto/Cartão), Plano (Básico/Premium)

Atributo de saída (variável-alvo): Cancelou? (Sim/Não)

ID	Uso do App	Pagamento	Plano	Cancelou?
1	Baixo	Boleto	Básico	Sim
2	Baixo	Boleto	Básico	Sim
3	Baixo	Cartão	Premium	Sim
4	Baixo	Cartão	Premium	Sim
5	Alto	Boleto	Premium	Não
6	Alto	Boleto	Premium	Não
7	Alto	Cartão	Básico	Não
8	Alto	Cartão	Básico	Não

Sobre a escolha da raiz da árvore, analise as afirmações a seguir:

- O atributo **Uso do App** apresenta um Ganho de Informação de 1, pois suas ramificações geram nós perfeitamente puros. **VERDADEIRA**
- Os atributos **Pagamento** e **Plano** apresentam Ganho de Informação igual a zero, uma vez que a distribuição das classes em seus subconjuntos permanece idêntica à do conjunto original. **VERDADEIRA**
- De acordo com o critério de maximização do ganho, qualquer um dos três atributos poderia ser escolhido como raiz sem prejuízo à eficiência da árvore. **FALSA (apenas o atributo Uso do App pode ser raiz)**

São CORRETAS as afirmações:

- Apenas I.
- Apenas II.
- Apenas I e II.**
- Apenas II e III.
- I, II e III.

ATENÇÃO: (1) A questão não será considerada sem apresentação dos cálculos. (2) Preencha os valores das entropias e ganhos de cada atributo na tabela abaixo.

Atributo	Entropia	Ganho de Informação
Uso do App	0	1
Pagamento	1	0
Plano	1	0

Passo 1: calcular a entropia do conjunto total (variável-alvo/target)

Sim: 4 exemplos $\rightarrow$ probabilidade = $4/8 = 1/2$

Não: 4 exemplos $\rightarrow$ probabilidade = $4/8 = 1/2$

$$\begin{aligned} H(\text{Cancelou?}) &= - (1/2 * \log_2(1/2) + 1/2 * \log_2(1/2)) \\ &= - (1/2 * (-1) + 1/2 * (-1)) \\ &= 1 \end{aligned}$$

Passo 2: calcular o ganho de informação de cada atributo que divide o conjunto em vários subconjuntos

- **Uso do App** divide em dois subconjuntos
 - **Uso do App=Baixo**, com 4 instâncias de 8 $\rightarrow$ tamanho relativo $4/8 = 1/2$
 - Dessas 4 instâncias (Uso do App=Baixo)
 - Em 4 delas, Cancelou=Sim $\rightarrow$ probabilidade = $4/4 = 1$
 - Em 0 delas, Cancelou=Não $\rightarrow$ probabilidade = $0/4 = 0$
 - **Uso do App=Alto**, com 4 instâncias de 8 $\rightarrow$ tamanho relativo $4/8$
 - Dessas 4 instâncias (Uso do App=Alto)
 - Em 0 delas, Cancelou=Sim $\rightarrow$ probabilidade = $0/4 = 0$
 - Em 4 delas, Cancelou=Não $\rightarrow$ probabilidade = $4/4 = 1$

$$\begin{aligned} H(\text{Uso do App}) &= 1/2 H(\text{Baixo}) + 1/2 H(\text{Alto}) \\ &= 1/2 [- (1 * \log_2(1) + 0 * \log_2(0))] \\ &\quad + 1/2 [- (0 * \log_2(0) + 1 * \log_2(1))] \\ &= 0 \end{aligned}$$

Ou seja, o meu ganho de informação para o atributo Uso do App será:

$$\begin{aligned} GI(\text{Uso do App}) &= H(\text{Cancelou?}) - H(\text{Uso do App}) \\ &= 1 - 0 \\ &= 1 \end{aligned}$$

- **Pagamento** divide em dois subconjuntos
 - **Pagamento=Boleto**, com 4 instâncias de 8 $\rightarrow$ tamanho relativo $4/8 = 1/2$
 - Dessas 4 instâncias (Pagamento=Boleto)
 - Em 2 delas, Cancelou=Sim $\rightarrow$ probabilidade = $2/4 = 1/2$
 - Em 2 delas, Cancelou=Não $\rightarrow$ probabilidade = $2/4 = 1/2$
 - **Pagamento=Cartão**, com 4 instâncias de 8 $\rightarrow$ tamanho relativo $4/8$
 - Dessas 4 instâncias (Pagamento=Cartão)
 - Em 2 delas, Cancelou=Sim $\rightarrow$ probabilidade = $2/4 = 1/2$
 - Em 2 delas, Cancelou=Não $\rightarrow$ probabilidade = $2/4 = 1/2$

$$\begin{aligned} H(\text{Pagamento}) &= 1/2 H(\text{Boleto}) + 1/2 H(\text{Cartão}) \\ &= 1/2 [- (1/2 * \log_2(1/2) + 1/2 * \log_2(1/2))] \\ &\quad + 1/2 [- (1/2 * \log_2(1/2) + 1/2 * \log_2(1/2))] \end{aligned}$$

$$= 1$$

Ou seja, o meu ganho de informação para o atributo Pagamento será:

$$GI(\text{Pagamento}) = H(\text{Cancelou?}) - H(\text{Pagamento})$$

$$= 1 - 1$$

$$= 0$$

- **Plano** divide em dois subconjuntos

- **Plano=Básico**, com 4 instâncias de 8 → tamanho relativo $4/8 = 1/2$

- Dessas 4 instâncias (Plano=Básico)

- Em 2 delas, Cancelou=Sim → probabilidade = $2/4 = 1/2$

- Em 2 delas, Cancelou=Não → probabilidade = $2/4 = 1/2$

- **Plano=Premium**, com 4 instâncias de 8 → tamanho relativo $4/8$

- Dessas 4 instâncias (Plano=Premium)

- Em 2 delas, Cancelou=Sim → probabilidade = $2/4 = 1/2$

- Em 2 delas, Cancelou=Não → probabilidade = $2/4 = 1/2$

$$H(\text{Plano}) = 1/2 H(\text{Básico}) + 1/2 H(\text{Premium})$$

$$= 1/2 [- (1/2 * \log_2(1/2) + 1/2 * \log_2(1/2))] + 1/2 [- (1/2 * \log_2(1/2) + 1/2 * \log_2(1/2))]$$

$$= 1$$

$$= 1$$

Ou seja, o meu ganho de informação para o atributo Plano será:

$$GI(\text{Plano}) = H(\text{Cancelou?}) - H(\text{Plano})$$

$$= 1 - 1$$

$$= 0$$

Passo 3: A raiz da árvore será o atributo com o maior ganho de informação. Sendo assim, escolhemos como raiz o atributo **Uso do App**.

Questão 14 (4 pontos)

Considere o conjunto de dados de referência da questão anterior (risco de *churn*) e uma nova instância com os seguintes atributos:

Uso do App	Baixo
Pagamento	Boleto
Plano	Básico

Utilizando o classificador Naive Bayes, calcule as probabilidades a posteriori (não normalizadas) para decidir se o cancelamento será realizado (Cancelou = Sim) ou não (Cancelou = Não).

ATENÇÃO: É obrigatório apresentar o desenvolvimento dos cálculos para validar a resposta.

Qual é o resultado correto da predição e os respectivos valores calculados?

- a) Cancelou = Não, com probabilidade proporcional a 0,125.
- b) Cancelou = Sim, com probabilidade proporcional a 0,125.
- c) Cancelou = Não, com probabilidade proporcional a 0,250.
- d) Cancelou = Sim, com probabilidade proporcional a 0,725.
- e) O modelo resulta em empate, exigindo um critério de desempate aleatório.

Primeiro, precisamos calcular as probabilidades a priori de cada classe:

$$p(\text{Cancelou} = \text{Sim}) = 4/8$$

$$p(\text{Cancelou} = \text{Não}) = 4/8$$

Agora, podemos calcular as probabilidades de cada atributo dada uma classe específica.

Por exemplo, a probabilidade do uso do app ser baixo, dado que uma pessoa cancelou, seria:

$$p(\text{Uso do App}=\text{Baixo} \mid \text{Cancelou}=\text{Sim}) = 4/4$$

Ou seja, de todas as vezes em que alguém cancelou (total de 4 vezes), em todas elas o uso do app era baixo.

De forma semelhante, podemos fazer o mesmo para o uso do app alto:

$$p(\text{Uso do App}=\text{Alto} \mid \text{Cancelou}=\text{Sim}) = 0/4$$

Então, podemos preencher a tabela com todas as probabilidades:

	Uso do App		Pagamento		Plano	
Cancelou?	Baixo	Alto	Boleto	Cartão	Básico	Premium
Sim 4/8	4/4	0/4	2/4	2/4	2/4	2/4
Não 4/8	0/4	4/4	2/4	2/4	2/4	2/4

Agora, podemos calcular os scores de probabilidade para cada classe dados os atributos do nosso exemplo de teste:

- $p(\text{Cancelou}=\text{Sim} \mid \text{Uso do App}=\text{Baixo}, \text{Pagamento}=\text{Boleto}, \text{Plano}=\text{Básico})$
 $\propto p(\text{Cancelou}=\text{Sim}) * p(\text{Cancelou}=\text{Sim} \mid \text{Uso do App}=\text{Baixo}) * p(\text{Cancelou}=\text{Sim} \mid \text{Pagamento}=\text{Boleto})$
 $\quad * p(\text{Cancelou}=\text{Sim} \mid \text{Plano}=\text{Básico})$
 $\propto 4/8 * 4/4 * 2/4 * 2/4$
 $\propto 0.125$
- $p(\text{Cancelou}=\text{Não} \mid \text{Uso do App}=\text{Baixo}, \text{Pagamento}=\text{Boleto}, \text{Plano}=\text{Básico})$
 $\propto p(\text{Cancelou}=\text{Não}) * p(\text{Cancelou}=\text{Não} \mid \text{Uso App}=\text{Baixo}) * p(\text{Cancelou}=\text{Não} \mid \text{Pagamento}=\text{Boleto})$
 $\quad * p(\text{Cancelou}=\text{Não} \mid \text{Plano}=\text{Básico})$
 $\propto 4/8 * 0 * 2/4 * 2/4 = 0$

Dessa forma, o Naive Bayes escolhe a classe cujo score é o maior, nesse caso **Cancelou=Sim**.

Questão 15 (4 pontos)

Analise o conjunto de dados das questões anteriores (risco de *churn*) como um conjunto de transações para mineração de regras de associação através do algoritmo Apriori. Considere os parâmetros: Suporte Mínimo = 30% (0,3) e Confiança Mínima = 60% (0,6). Avalie as seguintes regras propostas:

- I. A regra **{Uso do App = Alto} → {Cancelou = Não}** possui 50% de suporte e 100% de confiança. **VERDADEIRA**
- II. A regra **{Plano = Premium} → {Cancelou = Sim}** falha em ser selecionada por não atingir o suporte mínimo exigido, apesar de possuir confiança suficiente. **FALSA (não possui confiança suficiente)**
- III. A regra **{Pagamento = Boleto} → {Uso do App = Baixo}** falha tanto no critério de suporte quanto no de confiança. **VERDADEIRA**

São CORRETAS as afirmações:

- a) Apenas I.
- b) Apenas II.
- c) **Apenas I e III.**
- d) Apenas II e III.
- e) I, II e III.

ATENÇÃO: É obrigatório apresentar o desenvolvimento dos cálculos para validar a resposta.

Regra (A → B)	Suporte ({A, B})	Confiança (A → B)
{Uso do App = Alto} → {Cancelou = Não}	0.5	1
{Plano = Premium} → {Cancelou = Sim}	0.25	0.5
{Pagamento = Boleto} → {Uso do App = Baixo}	0.25	0.5

- **{Uso do App = Alto} → {Cancelou = Não}**
 - Suporte {Uso do App=Alto, Cancelou=Não} = $4/8 = 0.5 = 50\%$
 - Confiança = $\text{Suporte}(\{\text{Uso do App=Alto, Cancelou=Não}\}) / \text{Suporte}(\{\text{Uso do App=Alto}\})$
 $= 0.5 / 0.5 = 1$
- **{Plano = Premium} → {Cancelou = Sim}**
 - Suporte {Plano = Premium, Cancelou = Sim} = $2/8 = 0.25 = 25\%$
 - Confiança = $\text{Suporte}(\{\text{Plano=Premium, Cancelou=Sim}\}) / \text{Suporte}(\{\text{Plano=Premium}\})$
 $= 0.25 / 0.5 = 0.5$
- **{Pagamento = Boleto} → {Uso do App = Baixo}**
 - Suporte {Pagamento=Boleto, Uso do App=Baixo} = $2/8 = 0.25 = 25\%$
 - Conf. = $\text{Suporte}(\{\text{Pagamento=Boleto, Uso do App=Baixo}\}) / \text{Suporte}(\{\text{Pagamento=Boleto}\})$
 $= 0.25 / 0.5 = 0.5$