

RESOURCE MANAGEMENT FOR COGNITIVE CLOUD GAMING

Resource Management for Cognitive Cloud Gaming

Wei Cai¹, Min Chen², Conghui Zhao³, Victor C.M. Leung¹, Henry C.B. Chau¹
¹Department of Electrical and Computer Engineering, The University of British Columbia, Canada
²School of Computer Science and Technology, Hong Kong Polytechnic University, Hong Kong
³School of Computer Science and Technology, The Hong Kong Polytechnic University, Hong Kong

¹ {wei.cai, ming.chen}@ece.ubc.ca, ² minchen2012@ust.hk, ³ victor.leung@polyu.edu.hk

Abstract—In contrast to conventional gaming-on-demand solutions, cognitive cloud gaming platform facilitates gaming content, resource, and network management in a holistic manner. In this paper, we propose a cognitive cloud gaming platform that provides a novel flexible solution to provide gaming content and network resources in a holistic manner. We propose a cognitive cloud gaming platform that provides a novel flexible solution to provide gaming content and network resources in a holistic manner. We propose a cognitive cloud gaming platform that provides a novel flexible solution to provide gaming content and network resources in a holistic manner.

1. INTRODUCTION
Recently, there has been increasing interest in research, system designers, and application developers on a new type of cloud service mode generally known as Every-thing as a Service (EaaS) [1]. Along with this trend and the development of game industry, the transformation of traditional gaming service into Gaming as a Service (GaaS) becomes one of the most active research topics [2]. The GaaS model provides several advantages: (i) Scalability: it overcomes the capacity of traditional gaming hardware, including processing, data storage and battery in mobile devices; (ii) Cost-effectiveness: it reduces the production and maintenance cost of game development; (iii) Flexibility: it provides a flexible solution to provide gaming content and network resources in a holistic manner; (iv) Efficiency: it provides a flexible solution to provide gaming content and network resources in a holistic manner; (v) Scalability: it overcomes the capacity of traditional gaming hardware, including processing, data storage and battery in mobile devices; (vi) Cost-effectiveness: it reduces the production and maintenance cost of game development; (vii) Flexibility: it provides a flexible solution to provide gaming content and network resources in a holistic manner; (viii) Efficiency: it provides a flexible solution to provide gaming content and network resources in a holistic manner.

Resource Management for Cognitive Cloud Gaming

Wei Cai¹, Min Chen², Conghui Zhao³, Victor C.M. Leung¹, Henry C.B. Chau¹
¹Department of Electrical and Computer Engineering, The University of British Columbia, Canada
²School of Computer Science and Technology, Hong Kong Polytechnic University, Hong Kong
³School of Computer Science and Technology, The Hong Kong Polytechnic University, Hong Kong

¹ {wei.cai, ming.chen}@ece.ubc.ca, ² minchen2012@ust.hk, ³ victor.leung@polyu.edu.hk

Abstract—In contrast to conventional gaming-on-demand solutions, cognitive cloud gaming platform facilitates gaming content, resource, and network management in a holistic manner. In this paper, we propose a cognitive cloud gaming platform that provides a novel flexible solution to provide gaming content and network resources in a holistic manner. We propose a cognitive cloud gaming platform that provides a novel flexible solution to provide gaming content and network resources in a holistic manner.

1. INTRODUCTION
Recently, there has been increasing interest in research, system designers, and application developers on a new type of cloud service mode generally known as Everything as a Service (EaaS) [1]. Along with this trend and the development of game industry, the transformation of traditional gaming service into Gaming as a Service (GaaS) becomes one of the most active research topics [2]. The GaaS model provides several advantages: (i) Scalability: it overcomes the capacity of traditional gaming hardware, including processing, data storage and battery in mobile devices; (ii) Cost-effectiveness: it reduces the production and maintenance cost of game development; (iii) Flexibility: it provides a flexible solution to provide gaming content and network resources in a holistic manner; (iv) Efficiency: it provides a flexible solution to provide gaming content and network resources in a holistic manner; (v) Scalability: it overcomes the capacity of traditional gaming hardware, including processing, data storage and battery in mobile devices; (vi) Cost-effectiveness: it reduces the production and maintenance cost of game development; (vii) Flexibility: it provides a flexible solution to provide gaming content and network resources in a holistic manner; (viii) Efficiency: it provides a flexible solution to provide gaming content and network resources in a holistic manner.

INTEGRANTES

01. Felipe Gabriel de Carvalho

02. Fernando Theodoro Porto de Paula Dias

03. Gustavo Henrique dos Santos Dias

04. Raphael Oliveira de Araujo

05. Thiago Henrique Gomes Feliciano

06. Vitor Costa Oliveira Rolla



AGENDA DE APRESENTAÇÃO

1 Contexto e Motivação

2 Trabalhos
Relacionados

3 Arquitetura e
Plataforma

4 Modelagem e Controle
de QoS

5 Otimização e
Simulações

6 Conclusão e Discussão

INTRODUÇÃO AO CLOUD

GAMING E GAAS:

01 Conceito de Gaming as a Service (GaaS)



Modelo de negócio em que um jogo é tratado como um serviço contínuo, e não como um produto que é vendido uma única vez.



Escalabilidade

Supera limites de hardware dos terminais




Custo-efetivo

Desenvolvimento unificado



Multiplataforma

Supera limites de hardware dos terminais



Anti-pirataria

Jogo como serviço, não como produto



Click-and-Play

Jogue sem instalar

INTRODUÇÃO AO CLOUD

GAMING E GAAS:

02 Modelos de GaaS: RR-Gaas vs LR-Gaas



Remote Rendering(RR-Gaas)

Processamento: 100% na nuvem

Terminal: envia inputs, recebe vídeo

Rede: Alta largura de banda (vídeo HD)

Exemplo: Xbox Cloud Gaming



Local Rendering (LR-GaaS)

Processamento: Lógica na nuvem, render local

Terminal: Executa renderização gráfica

Rede: Menor (dados de estado)

Exemplo: Browser games

03 Problemas dos modelos atuais

01



Consumo Excessivo da Nuvem

- Capacidade física dos provedores é limitada
- Custo de uso proporcional ao consumo (pay-per-use)
- Pico de usuários sobrecarrega os servidores
- Sem adaptação ao estado real do sistema

02



Alto Throughput de Rede

- Toda comunicação passa pela Internet
- Congestionamento aumenta latência
- Consome franquia de dados móveis
- Piora a experiência (QoE) do jogador

03




Inflexibilidade e Desconexão

- Requer conexão contínua à Internet
- Desconexão suspende ou destrói a sessão
- Não há adaptação por dispositivo
- Pior em redes móveis instáveis

04 Por que um sistema cognitivo?

 **Ideia Central:** Migrar componentes do jogo da nuvem para o dispositivo do jogador, de forma **dinâmica e inteligente**, respeitando sempre a QoE mínima.



TRABALHOS RELACIONADOS E FUNDAÇÃO TEÓRICA

A. *Dynamic Partitioning*

Resource allocation optimization problem is intrinsically a group of dynamic partitioning problem for multiple devices. Researches on the dynamic partitioning between cloud and users' mobile terminal have been conducted for general-purpose applications. The work [6] first introduces a K-step algorithm to compute partitioning on-the-fly, when a phone connects to the server and specifies its resources and requirements. Furthermore, the work [7] formulates the dynamic partitioning problem and discusses the supporting platform to facilitate it. Afterwards, a dynamic partitioning system named CloneCloud is designed in the work [8]. As a flexible application partitioner and execution runtime, CloneCloud enables unmodified mobile applications running in an application-level virtual machine to seamlessly offload part of their execution from mobile devices onto device clones operating in a computational cloud. However, a basic requirement of these work is that, identical application copies shall be resided on both cloud and terminal in priori, which conflicts with our design requirement of "click-and-play" for the cloud-based games.

Dynamic Partitioning

- Calling the cloud: enabling mobile phones as interfaces to cloud applications
- Dynamically partitioning applications between weak devices and clouds
- Clonecloud: elastic execution between mobile device and cloud

TRABALHOS RELACIONADOS E FUNDAÇÃO TEÓRICA

B. Cognitive Cloud Gaming Platform

The work [5] first designs and implements a cognitive gaming platform that supports both “click-and-play” and cognitive resource allocation. The designated cognitive platform, consists of Information Collector, Performance Evaluator, On-loading Manager, Synchronization Controller, and Partitioning Coordinator, is able to dispatch selected gaming components from cloud to players’ terminal and later facilitate dynamic partitioning to adapt its service QoS to the real-time systemic environment. As a development-friendly environment, the platform also provides a set of application programming interfaces (APIs), so that the game developers need not to understand the lower layer resource management details but only focus on the design of game programs.

Cognitive Cloud Gaming Platform

- A cognitive platform for mobile cloud gaming

TRABALHOS RELACIONADOS E FUNDAÇÃO TEÓRICA

C. QoE for Cloud Gaming

Maintaining an acceptable QoE is an imperative design concern for cloud gaming systems. To provide GaaS, the relationships between cloud gaming QoE and QoS are different for distinct implementation architectures. For remote rendering GaaS, various subjective user studies have been conducted to demonstrate the relationship between cloud gaming QoE and QoS, including game genres, video encoding factors, CPU load, memory usage, and link bandwidth utilization [9], response latency and the game's real-time strictness [10], network characteristics (bit rates, packet sizes, and inter-packet times and an empirical network traffic analysis of On-Live and Gaikai [11]. However, the QoE to QoS mapping shall be redefined given the rendering component is resided on the local terminal. Due to multiple remote invoke between components, the impact of network QoS parameters will intensively impact the QoE for players.

QoE for Cloud Gaming


- An evaluation of qoe in cloud gaming based on subjective tests
- Are all games equally cloudgaming-friendly? an electromyographic approach
- An empirical study of cloud gaming

TRABALHOS RELACIONADOS E FUNDAMENTAÇÃO TEÓRICA

Limitações das abordagens existentes

- Exigência de Cópias
- Dependencia de Conexão Contínua

ARQUITETURA DA PLATAFORMA



Cognitive Resource Manager

Consciência dos recursos disponíveis em 3 pontos

- Nuvem
- Rede do usuário
- Dispositivo do usuário



COGNITIVE RESOURCE MANAGER

Information Collector

- Responsáveis por monitorar os recursos disponíveis ao longo do processo, existem tanto no lado da nuvem quanto no dispositivo

Performance Evaluator

- Recebe as informações na nuvem, e em conjunto com o local analyzer guia as decisões do sistema

COGNITIVE RESOURCE MANAGER


Onloading Manager

- Componente responsável por realizar a transferência do processamento da nuvem para o dispositivo do usuário através da rede

COGNITIVE RESOURCE MANAGER

Partitioning Coordinator

- Componente critico, responsavel pela comunicação entre os componentes do jogo, todos os fluxos de entrada e saída passam por ele.
- Por enviar e receber os dados do processamento descentralizado É o componente que realiza o corte de grafo ideal.



COGNITIVE RESOURCE MANAGER




Synchronization Controller

- Responsável pela centralização dos dados evitando erros lógicos no jogo como atrasos ou dessincronização, evitando que o jogo “quebre”

COGNITIVE RESOURCE MANAGER


Synchronization Controller
Partitioning Coordinator
Information Collector




Performance Evaluator

Local Analyzer

COGNITIVE RESOURCE MANAGER





MODELAGEM DO SISTEMA

Parte A: Componentes do jogo

Na arquitetura GaaS proposta, cada jogo consiste de componentes interdependentes que trabalham colaborativamente para fornecer serviços de renderização e lógica de jogo.

Grafo Direcionado

Modelado por $G = (C, E)$, onde cada vértice representa um componente c e cada aresta representa uma dependência entre componentes.

Estratégia de Corte



O particionamento inteligente busca definir qual subconjunto de componentes será executado no terminal local e qual ficará no servidor de nuvem.

MODELAGEM DO SISTEMA

Parte A: Parâmetros dos componentes

TABLE I
NOTATION I

Symbol	Definition
r_i	the resource consumption of c_i
s_i	the size of the compiled code of c_i
$in_{j,i}$	the amount of data that c_i takes in input from c_j
$out_{j,i}$	the amount of data that c_i sends in output to c_j
$fin_{j,i}$	the frequency that c_i takes data input from c_j
$fout_{j,i}$	the frequency that c_i sends data output to c_j



MODELAGEM DO SISTEMA

Parte A: Coordenação de Particionamento

Local Analyzer

Monitora continuamente a capacidade de memória, throughput real e largura de banda do dispositivo local do jogador.

Performance Evaluator


Avalia o desempenho de latência da rede e estima a latência de processamento das tarefas na nuvem e no dispositivo móvel.

Partitioning Coordinator

Centraliza todos os fluxos de dados de entrada e saída para calcular e implantar o corte de grafo ideal em tempo real.

MODELAGEM DO SISTEMA

Parte A: Representação através de grafos



MODELAGEM DO SISTEMA

Parte B: Controle de QoS Rígido

TABLE II
NOTATION 2

Symbol	Definition
$\{n n \in N\}$	the set of N terminals
σ	the set of components allocated in cloud
τ	the set of components allocated in terminal
$r(n)_i$	source consumption of c_i for terminal n
$d(n)_{i,j}$	throughput between c_i and c_j for terminal n
$l(n)_p$	process latency for terminal n
$l(n)_c$	communication latency for terminal n
L_M	maximal latency that player can tolerate
$T(n)_{RTT}$	Round Trip Time for terminal n
$F(n)_T$	time efficiency factor for terminal n
$F(n)_C$	time efficiency factor for cloud n
$R(n)_T$	the available resources in terminal n
$B(n)_T$	the available bandwidth in terminal n
R_C	the available resources in the cloud
B_C	the available bandwidth in the cloud

Parâmetros importantes

Autores definem diversas
modelagens matemáticas
para garantir controle de QoS

MODELAGEM DO SISTEMA

Parte B: Controle de QoS Rígido

1) Capacidade de recursos

O total de recursos de memória consumidos pelos componentes alocados no terminal local (t) não deve exceder a capacidade disponível de memória do terminal móvel (RT).

$$\sum_{c_i \in \tau} r(n)_i \leq R(n)_T, \forall n \in N$$

MODELAGEM DO SISTEMA

Parte B: Controle de QoS Rígido

2) Restrição de taxa de transferência do terminal (Bandalarga)

A restrição de throughput garante que o volume total de dados trocados entre os componentes do sistema não ultrapasse a largura de banda disponível em cada terminal. Isso ajuda a evitar congestionamentos na rede e mantém uma boa experiência para o jogador.

$$d(n)_{i,j} = fin(n)_{j,i} \cdot in(n)_{j,i} + fout(n)_{i,j} \cdot out_{i,j}$$

$$\sum_{\substack{c_i \in \tau \\ c_j \in \sigma}} d(n)_{i,j} \leq B(n)_T, \forall n \in N$$

MODELAGEM DO SISTEMA

Parte B: Controle de QoS Rígido

3) Restrição de latência de interação

A restrição de latência de interação garante que o tempo entre a ação do jogador e a resposta do sistema permaneça abaixo de um limite máximo aceitável. Tal latência é composta pela soma da latência de processamento dos componentes, executados no terminal e na nuvem, e da latência de comunicação gerada pela troca de dados entre componentes remotos.

$$l(n)_p = \sum_{c_i \in \tau} r(n)_i F(n)_T + \sum_{r_j \in \sigma} r(n)_j F(n)_C$$

$$l(n)_c + l(n)_p \leq L_M, \forall n \in N$$

$$l(n)_c = \sum_{\substack{c_i \in \tau \\ c_j \in \sigma}} f(d(n)_{i,j}, T(n)_{RTT})$$

MODELAGEM DO SISTEMA

Parte B: Controle de QoS Rígido

4) Restrições de recursos da nuvem

A restrição de recursos da nuvem garante que a quantidade de recursos consumidos pelos componentes hospedados não ultrapasse a capacidade disponível do provedor. Considerando a memória como principal indicador de consumo, essa restrição assegura que a infraestrutura consiga atender todos os terminais sem comprometer a qualidade do serviço (QoS).

$$\sum_{n \in N} \sum_{c_i \in \sigma} r(n)_i \leq R_C$$


MODELAGEM DO SISTEMA

Parte B: Controle de QoS Rígido

4) Restrição de capacidade de processamento na nuvem

A restrição de throughput da nuvem garante que o volume total de dados trafegados entre os terminais e a infraestrutura em nuvem não exceda sua capacidade de rede. Dessa forma, o sistema evita congestionamentos e mantém a qualidade do serviço para todos os jogadores conectados.

$$\sum_{n \in N} \sum_{\substack{c_i \in \tau \\ c_j \in \sigma}} d(n)_{i,j} \leq B_C$$



MODELAGEM DO SISTEMA

Parte C: Metas de Otimização

Minimização de Recursos

Desafio Econômico e Físico


A capacidade da nuvem é restrita por limites de virtualização e o uso dos servidores é cobrado em formato de pagamento por uso (pay-per-use).

Reduzir custos de operação da nuvem é de extrema importância, especialmente nos momentos de pico de acesso

Mecanismo de Descarregamento

O gerenciador monitora em tempo real a carga do servidor. Caso atinja um limite crítico, ele aloca dinamicamente mais componentes nos terminais locais mais potentes dos jogadores.

Todo o processo ocorre sob a tutela das restrições rígidas de QoS para proteger a experiência (QoE).



MODELAGEM DO SISTEMA

Parte C: Metas de Otimização

Otimização do Throughput

Combate ao Gargalo de Rede

A rede representa o calcanhar de Aquiles em sistemas de Cloud Gaming em tempo real.

Paralelamente, os jogadores que acessam os servidores por meio de conexões móveis pagas preocupam-se diretamente com o faturamento e os limites da sua franquia de dados.

Particionamento: Foco em Rede

O gerenciador cognitivo avalia o status individual e a qualidade de rede de cada terminal celular.

Ele calcula dinamicamente um particionamento focado em minimizar o throughput médio de todos os aparelhos conectados, garantindo o melhor fluxo de QoE para os usuários.

SIMULAÇÕES

01

Configuração das Simulações

Parâmetro	Valor
Memória da nuvem	100 GB
Banda da nuvem	1 Gbps
RTT dos terminais	10–25 ms
Banda dos terminais	80–120 kbps
Memória dos terminais	80–160 MB
Latência máxima (QoE)	120 ms
Repetições por experimento	1000

02

Comparação: Pure-Cloud Mode vs Cognitive Mode

Pure-Cloud Mode


Modelo convencional. Apenas Input e Output ficam no terminal. Todo o restante roda na nuvem.

Cognitive Mode

Modelo proposto. Componentes migram dinamicamente. O sistema escolhe a partição ótima para cada objetivo e cada terminal.

SIMULAÇÕES

03 Resultados




O gráfico compara o consumo de memória da nuvem à medida que o número de terminais aumenta.

- Pure-Cloud Mode: cresce quase linearmente com o número de terminais
- Cognitive Mode: cresce muito mais lentamente — parte da carga vai para os dispositivos
- Redução de até 50% no consumo de recursos da nuvem
- Impacto prático: servidor que suportava 1.000 jogadores passa a suportar ~2.000 com a mesma infraestrutura

SIMULAÇÕES

03 Resultados



Este gráfico mede a experiência do usuário.

- A latência não aumentou mesmo após a migração de componentes
- Em alguns cenários foi menor — componentes próximos ao usuário reduzem a comunicação remota
- Conclusão: o Cognitive Mode economiza recursos e melhora a responsividade simultaneamente

SIMULAÇÕES

03 Resultados




Fig. 7. Throughput Comparison for Throughput Oriented Optimization

Este gráfico avalia o consumo de rede.

- Pure-Cloud Mode: throughput alto pois toda comunicação passa pela rede
- Cognitive Mode: componentes que se comunicam muito são colocados no mesmo local, cortando o tráfego
- Redução de 55% no throughput médio dos terminais
- Benefícios: menos dados móveis, menor risco de congestionamento, menor latência

CONCLUSÃO, LIMITAÇÕES E TRABALHOS FUTUROS

Principais Contribuições do Artigo

Plataforma Cognitiva de Cloud Gaming

Propõe uma plataforma que migra componentes do servidor para o terminal do jogador com solução flexível de Gaming as a Service (GaaS) com suporte a "click-and-play".

Modelagem de Gerenciamento de Recursos

Formula o problema de alocação de recursos como um grafo dirigido de componentes, com restrições de memória, latência, largura de banda e recursos de nuvem.

Otimização Dupla

Demonstra dois alvos de otimização: (1) Minimização de Recursos na Nuvem e (2) Otimização Orientada a Throughput, garantindo QoE dos jogadores.

CONCLUSÃO, LIMITAÇÕES E TRABALHOS FUTUROS

Benefícios do Gerenciamento Cognitivo

Adaptação em Tempo Real

O Cognitive Resource Manager monitora continuamente os terminais e aloca dinamicamente componentes conforme as condições de rede e dispositivo mudam.

Resiliência à Desconexão

Componentes migrados para o terminal permitem que o jogo continue mesmo sem conexão à nuvem, preservando a QoE em redes móveis instáveis.

Menor Latência de Interação

Ao executar partes do jogo localmente, o modo Cognitivo reduz a latência de interação em comparação ao modo Pure-Cloud, segundo os experimentos.

CONCLUSÃO, LIMITAÇÕES E TRABALHOS FUTUROS

Redução de Recursos e Tráfego de Rede

50%

Redução de
Recursos na Nuvem

Modo Cognitivo vs. Pure-Cloud

2x


Mais Terminais
Atendidos

Com mesmos recursos de
nuvem

55%

Redução de
Throughput

Nos terminais dos jogadores




CONCLUSÃO, LIMITAÇÕES E TRABALHOS FUTUROS



Problema da Complexidade Computacional

- Busca exaustiva para achar o particionamento ótimo
- Complexidade da ordem de $2^{(NC)}$ — N terminais, C componentes
- Inviável conforme o número de terminais/componentes cresce
- Experimentos limitados a poucos dispositivos → resultados apenas preliminares



CONCLUSÃO, LIMITAÇÕES E TRABALHOS FUTUROS



Uso Futuro de Algoritmos Genéticos e Melhorias no Design dos Jogos

- Substituir busca exaustiva por algoritmo genético iterativo
- Buscar soluções viáveis em tempo real, mesmo em maior escala
- Investigar como o design do jogo afeta a otimização
- Explorar diferentes gêneros de jogos na plataforma

A pixel art illustration of a city skyline at night. The sky is dark blue with several small, fluffy white clouds. The city features various buildings: tall skyscrapers with glowing windows, a building with a red neon sign that says "HOTEL", and a building with a red neon sign that says "SURVIVE". The text "OBRIGADO" is written in large, white, pixelated letters with a red outline, and "PELA" is written in smaller, white, pixelated letters with a red outline. Below the text, the word "ATE" is written in large, white, pixelated letters with a red outline, followed by "ICADO!" in smaller, white, pixelated letters with a red outline.

OBRIGADO
PELA
ATE-ICADO!