

Segmentação de Imagens Baseada em Grafos: Comparação entre Árvore Geradora Mínima e Caminho Mínimo

Arthur Campos Pereira [✉] [Pontifícia Universidade Católica de Minas Gerais | 1401938@sga.pucminas.br]

Daniel Pedrosa Collina [✉] [Pontifícia Universidade Católica de Minas Gerais | 1320857@sga.pucminas.br]

Felipe Gabriel de Carvalho [✉] [Pontifícia Universidade Católica de Minas Gerais | 1543536@sga.pucminas.br]

Felipe Silva Barros [✉] [Pontifícia Universidade Católica de Minas Gerais | 1526815@sga.pucminas.br]

Gustavo Henrique dos Santos Dias [✉] [Pontifícia Universidade Católica de Minas Gerais | 1543570@sga.pucminas.br]

Miguel Pessoa Lima Ferreira [✉] [Pontifícia Universidade Católica de Minas Gerais | 1527129@sga.pucminas.br]

Raphael Oliveira de Araujo [✉] [Pontifícia Universidade Católica de Minas Gerais | 1496523@sga.pucminas.br]

Thiago Henrique Gomes Feliciano [✉] [Pontifícia Universidade Católica de Minas Gerais | 1543790@sga.pucminas.br]

[✉] Instituto de Ciências Exatas e Informática, Pontifícia Universidade Católica de Minas Gerais, R. Dom José Gaspar, 500 - Coração Eucarístico, Belo Horizonte - MG, 30535-901, Brasil.

Resumo: Este trabalho apresenta a implementação e análise de três abordagens de segmentação de imagens baseadas em grafos: uma segmentação adaptativa inspirada em Felzenszwalb-Huttenlocher, uma abordagem hierárquica baseada em MST e uma solução por caminho mínimo baseada na Transformada Imagem-Floresta. Em todas as soluções, a imagem é modelada como um grafo ponderado, no qual pixels são vértices, vizinhanças são arestas e os pesos representam diferenças de cor. As implementações foram desenvolvidas em C++ com OpenCV e comparadas qualitativamente em imagens coloridas e em níveis de cinza, considerando estrutura do grafo, critério de segmentação, visualização dos resultados e sensibilidade aos parâmetros.

Palavras-chave: Segmentação de Imagens; Teoria dos Grafos; Árvore Geradora Mínima; Caminho Mínimo; Processamento de Imagens.

1 Introdução

A segmentação de imagens constitui uma etapa fundamental em visão computacional, pois transforma uma imagem digital em uma representação composta por regiões mais homogêneas e, portanto, mais adequada para análise posterior. Em vez de tratar a imagem apenas como uma matriz de valores de cor, a segmentação busca agrupar pixels que apresentem propriedades semelhantes, como intensidade, cor ou continuidade espacial, ao mesmo tempo em que preserva diferenças relevantes entre regiões adjacentes.

Uma forma clássica de tratar esse problema em Ciência da Computação consiste em modelar a imagem como um grafo ponderado. Nessa representação, cada pixel é associado a um vértice, e as relações de vizinhança entre pixels são representadas por arestas. O peso de cada aresta expressa uma medida de dissimilaridade visual entre pixels vizinhos. Assim, pixels com cores semelhantes tendem a ser conectados por arestas de baixo peso, enquanto transições visuais mais fortes produzem arestas de peso elevado.

Este trabalho apresenta a implementação e análise de três abordagens de segmentação de imagens baseadas em grafos. A primeira solução utiliza uma estratégia inspirada no método de Felzenszwalb-Huttenlocher, no qual componentes são fundidos de acordo com um critério adaptativo baseado na diferença interna das regiões. A segunda solução constrói uma Árvore Geradora Mínima (MST) da imagem e explora segmentações hierárquicas por meio de diferentes limiares de corte, além da visualização normalizada dos pesos da MST. A terceira solução aplica a Transformada Imagem-Floresta (IFT), propagando rótulos a partir de se-

mentes distribuídas automaticamente na imagem.

O objetivo principal deste artigo é comparar qualitativamente essas três abordagens quanto à modelagem do grafo, ao critério de segmentação, à forma de visualização dos resultados e ao comportamento observado nas imagens processadas. Embora o trabalho não tenha como foco uma avaliação quantitativa extensiva, a comparação permite discutir as vantagens e limitações de cada método no contexto de segmentação baseada em grafos.

2 Metodologia

A metodologia adotada foi organizada em etapas relacionadas à definição das ferramentas utilizadas, estruturação do código, construção da infraestrutura de grafos, implementação dos algoritmos de segmentação e geração das visualizações resultantes.

2.1 Ferramentas Utilizadas e Protocolo Experimental

O projeto foi desenvolvido em C++, com uso da biblioteca OpenCV para leitura, manipulação e gravação das imagens. A compilação foi realizada com g++, em ambiente configurado no Visual Studio Code, utilizando o padrão C++17.

Os experimentos foram conduzidos com imagens coloridas e em níveis de cinza, contendo diferentes características visuais, como contornos definidos, texturas, fundos homogêneos e regiões de baixo contraste. Na Solução A, utilizou-se o parâmetro $k = 30000$; na Solução B, foram avalia-

dos os limiares $\lambda = \{1, 2, 3, 5, 10, 15, 20, 30, 40, 50\}$; e, na Solução C, utilizou-se o alvo de 300 sementes distribuídas automaticamente. A avaliação foi feita por inspeção visual, considerando preservação de bordas, fragmentação, suavização e comportamento hierárquico.

2.2 Estruturação do Código

O código foi dividido em arquivos independentes para cada solução, permitindo executar e avaliar separadamente cada abordagem. A Solução A está implementada em `solucaoA.cpp`, a Solução B em `solucaoB.cpp` e a Solução C em `solucaoC.cpp`. Os arquivos de cabeçalho correspondentes armazenam as estruturas de dados utilizadas, como vértices, arestas, conjuntos disjuntos e listas de adjacência.

Essa separação contribui para a organização do projeto, pois cada solução possui seu próprio fluxo de execução, parâmetros e diretórios de saída. As imagens segmentadas são salvas em subpastas específicas, permitindo comparar visualmente os resultados produzidos por cada método.

2.3 Infraestrutura de Grafos

Em todas as soluções, a imagem é representada como um grafo de grade. Cada pixel corresponde a um vértice identificado pela posição linear $i \cdot col + j$, em que i representa a linha, j representa a coluna e col representa a largura da imagem. A vizinhança considerada é 4-conexa, isto é, cada pixel é conectado apenas ao vizinho à direita e ao vizinho inferior durante a construção das arestas. Essa escolha evita duplicação de arestas e preserva a conectividade local da imagem.

Os pesos das arestas são calculados a partir da diferença de cor entre pixels vizinhos. Nas Soluções A e C, utiliza-se a soma das diferenças absolutas entre os canais BGR. Na Solução B, utiliza-se a distância euclidiana quantizada entre os valores dos canais BGR. Em ambos os casos, pesos baixos indicam alta similaridade visual, enquanto pesos elevados indicam maior descontinuidade entre regiões da imagem.

2.4 Algoritmos de Segmentação

2.4.1 Solução A: Segmentação Adaptativa

A Solução A implementa uma segmentação inspirada no algoritmo de Felzenszwalb-Huttenlocher [2004]. Inicialmente, todas as arestas do grafo são ordenadas em ordem crescente de peso, de modo semelhante ao processamento de Kruskal, mas sem materializar uma MST completa. Em seguida, cada pixel é tratado como um componente independente, mantido por uma estrutura de conjuntos disjuntos.

A fusão entre dois componentes ocorre quando o peso da aresta que os conecta é menor ou igual ao menor limiar interno entre os dois componentes. Esse limiar é definido pela soma entre a diferença interna do componente e o termo $\frac{k}{|C|}$, em que k é um parâmetro de escala e $|C|$ representa o tamanho do componente. No experimento implementado, utilizou-se $k = 30000$.

Essa abordagem tende a preservar regiões visualmente homogêneas e controlar o grau de fusão dos componentes conforme o tamanho das regiões aumenta. A saída é gerada em três modos de visualização: cores aleatórias por componente, tons de cinza por rótulo e cor média de cada segmento.

2.4.2 Solução B: MST Hierárquica

A Solução B constrói uma Árvore Geradora Mínima sobre o grafo da imagem, explorando conceitos associados a segmentações hierárquicas, zonas quase planas e mapas de saliência Cousty *et al.* [2018]. Para isso, as arestas são ordenadas por peso e processadas com uma estrutura de conjuntos disjuntos, de forma semelhante ao algoritmo de Kruskal. Após a construção da MST, diferentes segmentações são produzidas por meio de cortes baseados em limiares λ .

Foram considerados os valores $\lambda = \{1, 2, 3, 5, 10, 15, 20, 30, 40, 50\}$. Para cada valor, arestas da MST com peso menor ou igual ao limiar são utilizadas para unir componentes. Valores menores de λ tendem a gerar segmentações mais fragmentadas, enquanto valores maiores permitem maior fusão entre regiões.

Além das segmentações hierárquicas, a Solução B gera uma visualização normalizada dos pesos das arestas da MST, utilizada como aproximação diagnóstica de um mapa de saliência. Nessa visualização, os pesos são normalizados para o intervalo de intensidade de 0 a 255, destacando regiões em que há maior transição visual. Assim, a solução fornece uma representação complementar das descontinuidades presentes na imagem, embora não implemente integralmente a formulação hierárquica de saliência proposta na literatura.

2.4.3 Solução C: Transformada Imagem-Floresta

A Solução C implementa a Transformada Imagem-Floresta, conforme a formulação proposta por Falcão, Stolfi e Lotufo Falcão *et al.* [2004]. Nessa abordagem, sementes são distribuídas automaticamente em uma grade regular sobre a imagem. O parâmetro $n = 300$ controla a quantidade aproximada de sementes. O espaçamento entre elas é calculado pela raiz quadrada da razão entre o número total de pixels da imagem e o número desejado de sementes. Assim, as sementes são distribuídas de forma regular, próximas ao centro de cada intervalo da grade.

A partir dessas sementes, os rótulos são propagados pela imagem utilizando uma fila de prioridade. O custo de alcançar um pixel é definido pela função f_{peak} , isto é, o maior peso encontrado ao longo do caminho entre a semente e o pixel. Dessa forma, a propagação favorece caminhos que evitam atravessar arestas de alto peso, preservando fronteiras visuais mais fortes.

Ao final do processo, cada pixel recebe o rótulo da semente que o alcançou com menor custo. As saídas são geradas por cores aleatórias, escala de cinza baseada nos rótulos e cor média dos segmentos.

2.5 Pipeline de Segmentação

O pipeline geral adotado nas três soluções pode ser resumido nas seguintes etapas:

1. leitura da imagem de entrada com OpenCV;
2. criação dos vértices a partir dos pixels;
3. construção das arestas com vizinhança 4-conexa;
4. cálculo dos pesos com base na diferença de cor;
5. execução do algoritmo correspondente;
6. geração das imagens segmentadas;
7. gravação dos resultados em diretórios de saída.

Tabela 1. Comparação geral entre as soluções implementadas.

Sol.	Estrutura	Critério	Saídas
A	Componentes disjuntos	Fusão adaptativa por diferença interna e parâmetro k	RGB, cinza e cor média
B	Árvore Geradora Mínima	Corte hierárquico por λ e visualização da MST	Segmentações por λ e pesos normalizados
C	Floresta de caminhos ótimos	Propagação por sementes com custo f_{peak}	RGB, cinza e cor média

3 Resultados

Os resultados foram analisados qualitativamente a partir das imagens produzidas pelas três soluções. As imagens utilizadas apresentam diferentes níveis de complexidade visual, incluindo regiões homogêneas, contornos bem definidos, texturas e variações de iluminação.

3.1 Análise Qualitativa da Segmentação

A Solução A apresentou comportamento adequado para segmentações diretas, especialmente quando o objetivo é obter regiões conectadas com base na homogeneidade local de cor. O parâmetro k exerce influência direta no tamanho dos segmentos: valores maiores favorecem a fusão de componentes e reduzem a fragmentação da imagem. Como resultado, a segmentação por cor média tende a suavizar regiões internas, mantendo uma aproximação visual do conteúdo original.



A Solução B destacou-se pela capacidade de gerar uma sequência hierárquica de segmentações. Para valores baixos de λ , a imagem permanece mais fragmentada, preservando pequenas variações locais. À medida que λ aumenta, componentes conectados por arestas de maior peso passam a ser unidos, produzindo regiões maiores. Essa característica torna a solução útil para observar diferentes níveis de detalhe da imagem.

A visualização dos pesos da MST produzida pela Solução B complementa a análise, pois evidencia pontos de maior variação entre pixels vizinhos. Em imagens com contornos fortes, como animais sobre fundos contrastantes, essa visualização tende a destacar bordas importantes. Em regiões com textura ou ruído, entretanto, também podem surgir respostas fragmentadas, o que exige interpretação cuidadosa.


A Solução C apresentou comportamento dependente da distribuição das sementes. Como as sementes são posicionadas automaticamente em grade, a qualidade dos segmentos depende da relação entre o espaçamento das sementes e a estrutura visual da imagem. Em regiões homogêneas, a propagação tende a produzir segmentos coerentes. Em áreas com texturas finas ou mudanças suaves de cor, podem ocorrer divisões artificiais ou fusões indesejadas.

3.2 Análise Visual

As Figuras 1 e 2 apresentam a comparação visual das três soluções em uma imagem colorida e em uma imagem em níveis de cinza. Essa organização permite observar como cada abordagem se comporta diante de variações de cor, intensidade, textura e contraste.

**Figura 1.** Comparação visual em imagem colorida: entrada original, Solução A com $k = 30000$, Solução B com $\lambda = 30$ e Solução C com 308 sementes.**Figura 2.** Comparação visual em imagem em níveis de cinza: entrada original, Solução A com $k = 30000$, Solução B com $\lambda = 30$ e Solução C com 289 sementes.

A Figura 3 apresenta valores representativos da evolução da segmentação hierárquica na Solução B. Foram escolhidos limiares mais espaçados para evidenciar a transição entre segmentações mais fragmentadas e regiões mais fundidas.

**Figura 3.** Segmentações hierárquicas da imagem do gato pela Solução B para $\lambda = 5, 10, 20, 30$ e 50 .

3.3 Comparação das Soluções e Comportamento

Tabela 2. Síntese comparativa das soluções avaliadas.

Sol.	Vantagens	Limitações
A	Produz uma segmentação direta e de interpretação simples; ajustável pelo parâmetro k .	Sensível à escolha de k ; não fornece naturalmente múltiplos níveis hierárquicos.
B	Permite análise multi-escala por diferentes valores de λ ; gera visualização dos pesos da MST.	Exige escolha adequada de λ ; valores baixos podem gerar excesso de fragmentação.
C	Permite segmentação por competição entre sementes; usa custo de caminho mínimo.	Depende fortemente da quantidade e posição das sementes.

De modo geral, a Solução A mostrou-se adequada para obter uma segmentação única e direta, produzindo 1.548 regiões na imagem colorida do gato com $k = 30000$. A Solução B apresentou comportamento mais sensível ao limiar λ : para a mesma imagem, foram obtidas 54.820 regiões com $\lambda = 5$, 1.950 regiões com $\lambda = 30$ e 392 regiões com $\lambda = 50$. Já a Solução C produziu 308 regiões, destacando a influência direta da quantidade e da distribuição das sementes na segmentação.

Apesar dessas diferenças, as três soluções compartilham a mesma base conceitual: a imagem é modelada como grafo ponderado, e as fronteiras entre regiões são relacionadas aos pesos das arestas. A relação entre a Solução B e a Solução C aparece no uso da noção de gargalo: ao cortar a MST por um limiar global λ , a Solução B agrupa pixels conectados por arestas de peso suficientemente baixo; já a IFT da Solução C propaga rótulos a partir de sementes buscando caminhos cujo maior peso seja mínimo. Assim, ambas exploram a conectividade induzida pelos pesos do grafo, mas diferem no critério final de decisão: B produz componentes por limiares globais, C atribui cada pixel à semente de menor custo, e A utiliza um critério adaptativo dependente da diferença interna e do tamanho dos componentes.

4 Conclusão

Este trabalho apresentou a implementação e a análise qualitativa de três abordagens de segmentação de imagens baseadas em grafos. A modelagem da imagem como grafo ponderado mostrou-se adequada para representar relações locais entre pixels, permitindo aplicar métodos clássicos como Árvore Geradora Mínima e Caminho Mínimo ao particionamento visual.

A Solução A mostrou-se apropriada para obter uma segmentação direta, controlada pelo parâmetro k , enquanto a Solução B evidenciou forte sensibilidade ao limiar λ , produzindo diferentes níveis de fragmentação conforme o valor adotado. A Solução C destacou a influência das sementes na formação das regiões, gerando uma segmentação mais dependente da distribuição inicial dos rótulos. Os resultados

também indicam que a comparação visual deve considerar a quantidade de regiões produzidas, pois segmentações com aparência semelhante podem apresentar granularidades distintas. Como limitações, destacam-se a ausência de métricas quantitativas mais completas, a dependência de parâmetros fixos e a avaliação em um conjunto restrito de imagens. Como trabalhos futuros, recomenda-se medir o tempo de execução, testar novos parâmetros e comparar os resultados com segmentações de referência.

Declarações

Contribuição dos Autores

Gustavo Henrique dos Santos Dias e Thiago Henrique Gomes Feliciano contribuíram com o estudo e a implementação da Solução A. Felipe Gabriel de Carvalho e Raphael Oliveira de Araujo contribuíram com o estudo e a implementação da Solução B. Felipe Silva Barros e Daniel Pedrosa Collina contribuíram com o estudo e a implementação da Solução C. Miguel Pessoa Lima Ferreira e Arthur Campos Pereira contribuíram com a organização do manuscrito, revisão da escrita, formatação, organização das figuras e consolidação da análise dos resultados. Todos os autores revisaram e aprovaram a versão final do trabalho.

Conflito de Interesse

Os autores declaram que não possuem conflitos de interesse.

Disponibilidade de Dados e Materiais

Os dados e softwares produzidos neste estudo estão disponíveis em: <https://github.com/FelipeCarva0/Trabalho-Grafos>.

Referências

- Cousty, J., Najman, L., Kenmochi, Y., and Guimaraes, S. J. F. (2018). Hierarchical segmentations with graphs: Quasi-flat zones, minimum spanning trees, and saliency maps. *Journal of Mathematical Imaging and Vision*, 60(4):479–502. DOI: 10.1007/s10851-017-0768-7.
- Falcão, A. X., Stolfi, J., and Lotufo, R. d. A. (2004). The image foresting transform: Theory, algorithms, and applications. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 26(1):19–29. DOI: 10.1109/TPAMI.2004.1261076.
- Felzenszwalb, P. F. and Huttenlocher, D. P. (2004). Efficient graph-based image segmentation. *International Journal of Computer Vision*, 59(2):167–181. DOI: 10.1023/B:VISI.0000022288.19776.77.